

Les entrepôts de données

Lydie Soler
Janvier 2008



U.F.R. d'informatique

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration

Le contexte


- **Besoin:** prise de décisions stratégiques et tactiques
- **Pourquoi:** besoin de réactivité
- **Qui:** les décideurs (non informaticiens)
- **Comment:** répondre aux demandes d'analyse des données, dégager des informations qualitatives nouvelles



Les données utilisables par les décideurs

■ Données opérationnelles (de production)

- Bases de données (Oracle, SQL Server)
- Fichiers, ...
- Paye, gestion des RH, gestion des commandes...



■ Caractéristiques de ces données:


- Distribuées: systèmes éparpillés
- Hétérogènes: systèmes et structures de données différents
- Détaillées: organisation des données selon les processus fonctionnels, données surabondantes pour l'analyse
- Peu/pas adaptées à l'analyse : les requêtes lourdes peuvent bloquer le système transactionnel
- Volatiles: pas d'historisation systématique

Problématique

- Comment répondre aux demandes des décideurs?
 - En donnant un accès rapide et simple à l'information stratégique
 - En donnant du sens aux données
- ➡ Mettre en place un système d'information dédié aux applications décisionnelles:
 - un data warehouse


Le processus de prise de décision

Champs d'application des
systèmes décisionnels



Temps de prise d'une décision

Le processus de prise de décision



Domaines d'utilisation des DW

- Banque
 - Risques d'un prêt, prime plus précise
- Santé
 - Épidémiologie
 - Risque alimentaire
- Commerce
 - Ciblage de clientèle
 - Déterminer des promotions
- Logistique
 - Adéquation demande/production
- Assurance
 - Risque lié à un contrat d'assurance (voiture)
- ...

Quelques métiers du décisionnel

- **Strategic Performance Management**
 - Déterminer et contrôler les indicateurs clé de la performance de l'entreprise
- **Finance Intelligence**
 - Planifier, analyser et diffuser l'information financière. Mesurer et gérer les risques
- **Human Capital Management** (gestion de la relation avec les employés)
 - Aligner les stratégies RH, les processus et les technologies.
- **Customer Relationship Management** (gestion de la relation client)
 - Améliorer la connaissance client, identifier et prévoir la rentabilité client, accroître l'efficacité du marketing client
- **Supplier Relationship Management** (gestion de la relation fournisseur)
 - Classifier et évaluer l'ensemble des fournisseurs. Planifier et piloter la stratégie Achat.

Plan

- Introduction
- **Les entrepôts de données**
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration


Définition d'un DW

- W. H. Inmon (1996):
« Le data Warehouse est une collection de données **orientées sujet, intégrées, non volatiles** et **historisées**, organisées pour le support d'un processus d'aide à la décision »
- Principe: mettre en place une base de données utilisée à des fins d'analyse

Les 4 caractéristiques des data warehouse

Données orientées sujet:


- Regroupe les informations des différents métiers
- Ne tiens pas compte de l'organisation fonctionnelle des données



Les 4 caractéristiques des data warehouse

Données intégrées:



- Normalisation des données
- Définition d'un référentiel unique



Les 4 caractéristiques des data warehouse

Données non volatiles

- Traçabilité des informations et des décisions prises
- Copie des données de production



Les 4 caractéristiques des data warehouse

Données datées

- Les données persistent dans le temps
- Mise en place d'un référentiel temps

Base de
production

Image de la base en Mai 2005

Répertoire

Nom	Ville
Dupont	Paris
Durand	Lyon

Image de la base en Juillet 2006

Répertoire

Nom	Ville
Dupont	Marseille
Durand	Lyon

Entrepôt
de
données


Calendrier

Code	Année	Mois
1	2005	Mai
2	2006	Juillet

Répertoire

Code	Année	Mois
1	Dupont	Paris
1	Durand	Lyon
2	Dupont	Marseille

SGBD et DW



OLTP VS DW


OLTP	DW
Orienté transaction	Orienté analyse
Orienté application	Orienté sujet
Données courantes	Données historisées
Données détaillées	Données agrégées
Données évolutives	Données statiques
Utilisateurs nombreux, administrateurs/opérationnels	Utilisateurs peu nombreux, manager
Temps d'exécution: court	Temps d'exécution: long

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration

Datamart

- Sous-ensemble d'un entrepôt de données
- Destiné à répondre aux besoins d'un secteur ou d'une fonction particulière de l'entreprise
- Point de vue spécifique selon des critères métiers




Intérêt des datamart

- Nouvel environnement structuré et formaté en fonction des besoins d'un métier ou d'un usage particulier
- Moins de données que DW
 - Plus facile à comprendre, à manipuler
 - Amélioration des temps de réponse
- Utilisateurs plus ciblés: DM plus facile à définir

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- **Architecture**
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration

Architecture générale



Les flux de données

- Flux entrant
 - Extraction: multi-source, hétérogène
 - Transformation: filtrer, trier, homogénéiser, nettoyer
 - Chargement: insertion des données dans l'entrepôt
- Flux sortant:
 - Mise à disposition des données pour les utilisateurs finaux

Les différentes zones de l'architecture

- Zone de préparation (Staging area)
 - Zone temporaire de stockage des données extraites
 - Réalisation des transformations avant l'insertion dans le DW:
 - Nettoyage
 - Normalisation...
 - Données souvent détruites après chargement dans le DW
- Zone de stockage (DW, DM)
 - On y transfère les données nettoyées
 - Stockage permanent des données
- Zone de présentation
 - Donne accès aux données contenues dans le DW
 - Peut contenir des outils d'analyse programmés:
 - Rapports
 - Requêtes...

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- **Modélisation**
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration

Modélisation Entité/Association

■ Avantages:

■ Normalisation:

- Éliminer les redondances
- Préserver la cohérence des données

■ Optimisation des transactions

■ Réduction de l'espace de stockage

■ Inconvénients pour un utilisateur final:


■ Schéma très/trop complet:

- Contient des tables/champs inutiles pour l'analyse

■ Pas d'interface graphique capable de rendre utilisable le modèle E/A

■ Inadapté pour l'analyse

Exemple



Modélisation des DW

- Nouvelle méthode de conception autour des concepts métiers
 - Ne pas normaliser au maximum
- Introduction de nouveaux types de table:
 - Table de faits
 - Table de dimensions
- Introduction de nouveaux modèles:
 - Modèle en étoile
 - Modèle en flocon

Table de faits

- Table principale du modèle dimensionnel
- Contient les données observables (les faits) sur le sujet étudié selon divers axes d'analyse (les dimensions)

Clés étrangères
vers les
dimensions

Faits

Table de faits des ventes
Clé date (CE)
Clé produit (CE)
Clé magasin (CE)
Quantité vendue
Coût
Montant des ventes

Table de faits (suite)

■ Fait:

- Ce que l'on souhaite mesurer
 - Quantités vendues, montant des ventes...
- Contient les clés étrangères des axes d'analyse (dimension)
 - Date, produit, magasin
- Trois types de faits:
 - Additif
 - Semi additif
 - Non additif

Typologie des faits

- Additif: additionnable suivant toutes les dimensions
 - Quantités vendues, chiffre d'affaire
 - Peut être le résultat d'un calcul:
 - Bénéfice = montant vente - coût
- Semi additif: additionnable suivant certaines dimensions
 - Solde d'un compte bancaire:
 - Pas de sens d'additionner sur les dates car cela représente des instantanés d'un niveau
 - Σ sur les comptes: on connaît ce que nous possédons en banque
- Non additif: fait non additionnable quelque soit la dimension
 - Prix unitaire: l'addition sur n'importe quelle dimension donne un nombre dépourvu de sens

Granularité de la table de faits

- Répondre à la question :
 - Que représente un enregistrement de la table de faits?
- La granularité définit le niveau de détails de la table de faits:
 - Exemple: une ligne de commande par produit, par client et par jour




Table de dimension

- Axe d'analyse selon lequel vont être étudiées les données observables (faits)
- Contient le détail sur les faits

Dimension produit	
Clé de substitution	Clé produit (CP)
	Code produit
Attributs de la dimension	Description du produit
	Famille du produits
	Marque
	Emballage
	Poids

Table de dimension (suite)

- Dimension = axe d'analyse
 - Client, produit, période de temps...
- Contient souvent un grand nombre de colonnes
 - L'ensemble des informations descriptives des faits
- Contient en général beaucoup moins d'enregistrements qu'une table de faits

La dimension Temps

- Commune à l'ensemble du DW
- Reliée à toute table de faits

Dimension Temps
Clé temps (CP)
Jour
Mois
Trimestre
Semestre
Année
Num_jour_dans_année
Num_semaine_ds_année

Granularité d'une dimension

- Une dimension contient des membres organisés en hiérarchie :
 - Chacun des membres appartient à un niveau hiérarchique (ou niveau de granularité) particulier
 - Granularité d'une dimension : nombre de niveaux hiérarchiques
 - Temps :
 - année – semestre – trimestre - mois

Évolution des dimensions

- Dimensions à évolution lente
- Dimensions à évolution rapide

Évolution des dimensions

■ Dimensions à évolution lente

- Un client peut se marier, avoir des enfants...
- Un produit peut changer de noms ou de formulation:
 - « Raider » en « Twix »
 - « yaourt à la vanille » en « yaourt saveur vanille »
- Gestion de la situation, 3 solutions:
 - Écrasement de l'ancienne valeur
 - Versionnement
 - Valeur d'origine / valeur courante

■ Dimensions à évolution rapide

Dimensions à évolution lente (1/3)

■ Écrasement de l'ancienne valeur :

- Correction des informations erronées

■ Avantage:

- Facile à mettre en œuvre

■ Inconvénients:

- Perte de la trace des valeurs antérieures des attributs
- Perte de la cause de l'évolution dans les faits mesurés

Clé produit	Description du produit	Groupe de produits
12345	Intelli-Kids	Logiciel

Jeux éducatifs

Dimensions à évolution lente (2/3)

■ Ajout d'un nouvel enregistrement:

- Utilisation d'une clé de substitution

■ Avantages:

- Permet de suivre l'évolution des attributs
- Permet de segmenter la table de faits en fonction de l'historique

■ Inconvénient:

- Accroît le volume de la table

Clé produit	Description du produit	Groupe de produits
12345	Intelli-Kids	Logiciel
25963	Intelli-Kids	Jeux éducatifs

Dimensions à évolution lente (3/3)

■ Ajout d'un nouvel attribut:

- Valeur origine/valeur courante

■ Avantages:

- Avoir deux visions simultanées des données :
 - Voir les données récentes avec l'ancien attribut
 - Voir les données anciennes avec le nouvel attribut
- Voir les données comme si le changement n'avait pas eu lieu

■ Inconvénient:

- Inadapté pour suivre plusieurs valeurs d'attributs intermédiaires

Clé produit	Description du produit	Groupe de produits	Nouveau groupe de produits
12345	Intelli-Kids	Logiciel	Jeux éducatifs ⁴¹


Évolution des dimensions

- Dimensions à évolution lente
- Dimensions à évolution rapide
 - Subit des changements très fréquents (tous les mois) dont on veut préserver l'historique
 - Solution: isoler les attributs qui changent rapidement


Dimensions à évolution rapide

- Changements fréquents des attributs dont on veut garder l'historique
 - Clients pour une compagnie d'assurance
- Isoler les attributs qui évoluent vite


Dimensions à évolution rapide (suite)



Les types de modèles



Modèle en étoile




Modèle en flocon

Modèle en étoile

- Une table de fait centrale et des dimensions
- Les dimensions n'ont pas de liaison entre elles
- Avantages:
 - Facilité de navigation
 - Nombre de jointures limité
- Inconvénients:
 - Redondance dans les dimensions
 - Toutes les dimensions ne concernent pas les mesures


Modèle en étoile



Modèle en flocon

- Une table de fait et des dimensions décomposées en sous hiérarchies
- On a un seul niveau hiérarchique dans une table de dimension
- La table de dimension de niveau hiérarchique le plus bas est reliée à la table de fait. On dit qu'elle a la granularité la plus fine
- Avantages:
 - Normalisation des dimensions
 - Économie d'espace disque
- Inconvénients:
 - Modèle plus complexe (jointure)
 - Requêtes moins performantes

Modèle en flocon



Méthodologie: 9 étapes de Kimball

 **Choisir le sujet**

 **Choisir la granularité des faits**

 **Identifier et adapter les dimensions**

 **Choisir les faits**

 **Stocker les pré-calculs**

 **Établir les tables de dimensions**

 **Choisir la durée de la base**

 **Suivre les dimensions lentement évolutives**

 **Décider des requêtes prioritaires, des modes de requêtes**

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration

Alimentation/ mise à jour de l'entrepôt

- Entrepôt mis à jour régulièrement
 - Besoin d'un outil permettant d'automatiser les chargements dans l'entrepôt
- ⇒ Utilisation d'outils ETL (Extract, Transform, Load)

Définition d'un ETL

- Offre un environnement de développement
- Offre des outils de gestion des opérations et de maintenance
- Permet de découvrir, analyser et extraire les données à partir de sources hétérogènes
- Permet de nettoyer et standardiser les données
- Permet de charger les données dans un entrepôt

Extraction

- Extraire des données des systèmes de production
- Dialoguer avec différentes sources:
 - Base de données,
 - Fichiers,
 - Bases propriétaires
- Utilise divers connecteurs :
 - ODBC,
 - SQL natif,
 - Fichiers plats


Transformation

- Rendre cohérentes les données des différentes sources
 - Transformer, nettoyer, trier, unifier les données
 - Exemple: unifier le format des dates
(MM/JJ/AA $\Rightarrow$ JJ/MM/AA)
- Etape très importante, garantit la cohérence et la fiabilité des données

Chargement

- Insérer ou modifier les données dans l'entrepôt
- Utilisation de connecteurs:
 - ODBC,
 - SQL natif,
 - Fichiers plats


Aperçu d'un ETL



Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Accès à l'information
- Démonstration

OLTP VS OLAP



ROLAP

- Relational OLAP
 - Données stockées dans une base de données relationnelles
 - Un moteur OLAP permet de simuler le comportement d'un SGBD multidimensionnel
- Plus facile et moins cher à mettre en place
- Moins performant lors des phases de calcul
- Exemples de moteurs ROLAP:
 - Mondrian

MOLAP

- Multi dimensional OLAP:
 - Utiliser un système multidimensionnel « pur » qui gère les structures multidimensionnelles natives (les cubes)
 - Accès direct aux données dans le cube
- Plus difficile à mettre en place
- Formats souvent propriétaires
- Conçu exclusivement pour l'analyse multidimensionnelle
- Exemples de moteurs MOLAP:
 - Microsoft Analysis Services
 - Hyperion

HOLAP


- Hybride OLAP:
 - tables de faits et tables de dimensions stockées dans SGBD relationnel (données de base)
 - données agrégées stockées dans des cubes
- Solution hybride entre MOLAP et ROLAP
- Bon compromis au niveau coût et performance

Le cube

- Modélisation multidimensionnelle des données facilitant l'analyse d'une quantité selon différentes dimensions:
 - Temps
 - Localisation géographique
 - ...
- Les calculs sont réalisés lors du chargement ou de la mise à jour du cube

Manipulation des données multidimensionnelles


- Opération agissant sur la structure
 - Rotation (rotate): présenter une autre face du cube



Manipulation des données multidimensionnelles


■ Opération agissant sur la structure

- Tranchage (slicing): consiste à ne travailler que sur une tranche du cube. Une des dimensions est alors réduite à une seule valeur



Manipulation des données multidimensionnelles


- Opération agissant sur la structure
 - Extraction d'un bloc de données (dicing): ne travailler que sous un sous-cube



Manipulation des données multidimensionnelles

- Opération agissant sur la granularité
 - Forage vers le haut (roll-up): « dézoomer »
 - Obtenir un niveau de granularité supérieur
 - Utilisation de fonctions d'agrégation
 - Forage vers le bas (drill-down): « zoomer »
 - Obtenir un niveau de granularité inférieur
 - Données plus détaillées

Drill-up, drill-down



MDX (Multidimensional Expressions)

- Langage permettant de définir, d'utiliser et de récupérer des données à partir d'objets multidimensionnels
 - Permet d'effectuer les opérations décrites précédemment
- Equivalent de SQL pour le monde OLAP
- Origine: Microsoft

MDX, exemple

- Fournir les effectifs d'une société pendant les années 2004 et 2005 croisés par le type de paiement

```
SELECT {([Time].[2004]), ([Time].[2005])} ON COLUMNS,  
{[Pay].[Pay Type].Members} ON ROWS  
FROM RH  
WHERE ([Measures].[Count])
```




	2004	2005
Heure	3396	4015
Jour	3678	2056

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Le marché du décisionnel
- Démonstration


Le marché du décisionnel

Le marché en 2004



Quelques solutions commerciales

 **Business Objects™**



COGNOS®

 **Hyperion™**

Microsoft®

 **sas.** |

ORACLE®
FRANCE

Ab INITIO



Quelques solutions open source

ETL	Entrepôt de données	OLAP	Reporting	Data Mining
■ Octopus ■ Kettle ■ CloverETL ■ Talend	■ MySql ■ Postgresql ■ Greenplum/Bizgres	■ Mondrian ■ Palo	■ Birt ■ Open Report ■ Jasper Report	■ Weka ■ R-Project ■ Orange ■ Xelopes
■ JFreeReport				
Intégré				
■ Pentaho (Kettle, Mondrian, JFreeReport, Weka) ■ SpagoBI				

Plan

- Introduction
- Les entrepôts de données
- Les datamart
- Architecture
- Modélisation
- Alimentation
- Les bases de données multidimensionnelles
- Accès à l'information
- **Démonstration**

Exemples

- Rappports
 - Sales by customer
 - Dashboard
- Analyse

