

Entrepôts de données (Data Warehouses)

Thibault Estier

Ecole des HEC

Université de Lausanne

thibault.estier@hec.unil.ch

Entrepôts de données: principes et définitions

- Références:
 - Data Warehousing, Data Mining, &OLAP, **Alex Berson & Stephen J. Smith**, McGraw-Hill, 1997, 606 pages, ISBN=0-07-006272-2
 - Entrepôts de données, guide pratique du concepteur de « data warehouses » **Ralph Kimball**, International Thomson Publishing France, Paris, 1997, 360 pages + 1 CD-ROM, ISBN=2-84180-021-0

Motivation des Entrepôts de données

- Transformer les « données » des systèmes d'information opérationnels en « informations »

données —————→ **informations**
run the business *manage the business*

- intégrer différentes bases de données opérationnelles
- donner l'accès aux informations du passé
- fournir des outils d'analyse sur ces données
- informations comme:
 - agrégations de données,
 - résumé de données
 - interpolation de données manquantes
- réconcilier des données inconsistantes

OLTP <-> OLAP

- On Line Transaction Processing
 - opérations automatisées répétitives
 - courtes transactions, isolées
 - données détaillées, et instantanées
 - lire et mettre-à-jour très rapidement quelques données
 - données orientées « application »
- On Line Analytical Processing
 - analyses selon des modes imprévisibles, adhoc
 - données combinées de sources diverses
 - données historisées, résumés temporels
 - lire des millions de données, ne jamais mettre-à-jour,
 - données orientées « sujet »

Conséquence: Incompatibilités des deux activités

- Les deux activités (OLTP & OLAP) ne peuvent pas co-exister sur des données dans le **même** système d'information: leurs objectifs de performance sont exactement opposés:
 - les requêtes complexes et lourdes fusillent les performances des systèmes transactionnels,
 - les données temporelles sont réparties entre données *actuelles* et données *archivées*, rendant la vue historique des données très difficile ou impossible,
- ==> le support efficace d'une activité OLAP nécessite la constitution d'un système d'information propre: l'entrepôt de données.

Définition

Un entrepôt de données (*data warehouse*) est un ensemble *unique, complet* et *consistant* de données obtenues depuis une variété de *sources* et rendu *disponible* à des utilisateurs finaux à des fins de compréhension et de gestion des affaires décrites par ces données.


(d'après B. Devlin, Journal of Data Warehouses, nov. 1997)

Propriétés:

un data warehouse est:

- orienté sujets
- intégré
- défini par rapport au temps
- persistant sur le moyen à long terme


Modélisation dimensionnelle des données



Le cube des ventes: chaque point représente un “fait de vente”:
[*la semaine 23, on a vendu 50 paires de jeans à Lausanne*]

Schémas de bases de données pour les Entrepôts

- Schémas en étoile (STAR)
- une table centrale contient tous les faits à analyser,
- pour chaque dimension / paramètre de la table des faits, on a une table qui définit une des clés étrangère de la table de faits.




Processus de conception pour une base de données dimensionnelle (*R. Kimball*)

1. Choisir le processus d'activités opérationnelles à modéliser
 - Ex: les commandes, la facturation, les stocks, les ventes, etc...
2. Choisir la granularité du processus d'activité (le niveau de détail fondamental)
 - Ex: chaque transaction commerciale, ou une récapitulation quotidienne des transactions par client, ou une balance mensuelle du niveau de stock de chaque article, etc... Chaque « grain » sera une entité de la table des faits.
3. Choisir les dimensions applicables à chaque fait
 - Ex: Pour un fait de vente, le temps, le produit, le client (ou sa localisation), le type de transaction commerciale, la promotion, le statut de cette vente, etc...
 - Pour chaque dimension retenue on construira une table de dimension
4. Choisir les mesures appliquées à chaque fait
 - Ex: toutes infos retenues pour caractériser un fait deviendront des attributs de la table des faits.

Architectures d'entrepôts de données

1. L'entrepôt **virtuel** (ou le non-entrepôt)




Inconvénients:

- pas de réelle intégration des données
- différentes vues non-réconciliées
- pas de vues dans le temps
- les requêtes peuvent facilement bloquer les transactions en cours


Architectures d'entrepôts de données

2. Les paniers de données adhoc (Data Marts)



Architectures d'entrepôts de données

2. Les paniers de données adhoc (Data Marts)



Avantages:


- plus d'interférences avec les BD opérationnelles,
- données consolidées et temporalisées

Inconvénients:

- pas de vue d'ensemble des données
- risque de divergences d'interprétations
- pertes dues aux recouvrements (importants) de données entre data marts.

Architectures d'entrepôts de données

3. L'entrepôt centralisé




Avantages supplémentaires:

- exploitation d'informations unifiée sur toute l'organisation,
- paniers de données spécialisés pour des besoins particuliers:
 - agrégations pré-calculées
 - index ajustés pour de meilleures performances,
 - SGBD 's spécialisés

Architectures d'entrepôts de données

4. L'entrepôt centralisé et sa description: le meta-dictionnaire



Les outils d'extraction

- Fonctions attendues:
 - Transformation de données
 - Unification des représentations
 - Corrections d'irrégularités
 - Définition automatique / maintenance des meta-données

Transformation des données

- 1) Conversion de formats: des formats de la base opérationnelle dans les formats de la base de l'entrepôt,
- 2) uniformisation/réduction des valeurs de clés (pour éviter de surcharger les index de l'entrepôt)
- 3) convertir / uniformiser les noms des attributs (D-Naiss, Naissance, Date_N, etc.) --> « date_naissance »
- 4) uniformiser les valeurs d'attributs (1923, 16.10.1923, 16-octobre-23) --> 19231016,
- 5) uniformiser les tables de codes internes (1001 = roue, 1002 = cadre, 1003 = guidon, 1004 = pédale, ...), substituer par des tables de conversion dans le meta-dictionnaire.

Nettoyage des données

- Ajouter des règles d'intégrité au module d'extraction des données pour:
 - identifier et corriger les valeurs invalides
 - identifier (et remplacer) les valeurs manquantes
 - traiter les violations de contraintes d'intégrité
- Ajouter des heuristiques au module d'extraction des données pour:
 - trouver si deux entités représentent la même information,
 - pour ajouter des attributs à certaines entités

Outils ETL (Extract, Transform and Load)

- Langages de spécifications déclaratives (plutôt que des scripts fixes écrits à la main)
- 2 approches:
 - générateurs de programmes d'extraction
 - moteurs d'extractions pilotés par les règles déclaratives
- Les générateurs de programme ont l'avantage généralement de permettre la mise-à-jour en même temps du meta-dictionnaire.

Le double rôle des meta-données

- Faciliter l'administration et le développement de l'entrepôt de données:
 - décrire les situations de données intégrées / uniformisées
 - faciliter la conception de nouvelles applications d'analyse de données
 - permettre l'automatisation de processus réguliers de maintenance de l'entrepôt,
- Faciliter l'extraction périodique de données depuis les bases opérationnelles
 - augmenter la qualité des données (en fournissant les valeurs de références et en permettant (parfois) d'inférer des valeurs manquantes,
 - renforcer une terminologie unique à travers les différents outils d'analyse (et donc à travers les différents Data Marts.