




Data warehouse


- ◆ Motivations et architecture
- ◆ Conception de la BD support
- ◆ Alimentation du DW
- ◆ Exploitation OLAP
- ◆ Conclusion

1. OLTP et OLAP



Explosion de l'OLAP

◆ Facteurs économiques & technologiques



Motivations des entreprises

- ◆ Besoin des entreprises
 - accéder à toutes les données de l'entreprise
 - regrouper les informations disséminées
 - analyser et prendre des décisions rapidement (OLAP)
- ◆ Exemples d'applications concernées
 - Grande distribution : marketing, maintenance, ...
 - produits à succès, modes, habitudes d'achat
 - préférences par secteurs géographiques
 - Bancaire : suivi des clients, gestion de portefeuilles
 - mailing ciblés pour le marketing
 - Télécommunications : pannes, fraudes, mobiles, ...
 - classification des clients, détection fraudes, fuites de clients

Datawarehouse : définition


◆ Entrepôt de données

- Ensemble de données historisées variant dans le temps, organisé par sujets, consolidé dans une base de données unique, géré dans un environnement de stockage particulier, aidant à la prise de décision dans l'entreprise.

◆ Trois fonctions essentielles :


- collecte de données de bases existantes et chargement
- gestion des données dans l'entrepôt
- analyse de données pour la prise de décision

Architecture type



Datamart (Magasin de données)

- ◆ sous-ensemble de données [extrait du DW] et ciblé sur un sujet unique



2. Concevoir le DW


- ◆ Export de données des sources
 - Hétérogènes et variées
 - Fichiers, BD patrimoniales, Web, ...
 - Définition des vues exportées
- ◆ Définition d'un schéma global
 - Intègre les données utiles
 - S'appuie sur le modèle relationnel
- ◆ Nécessité d'une gestion de méta-données
 - Description des sources
 - Description des vues exportées
 - Description du schéma global

Organisation par sujet

- ◆ Les données sont organisées par sujets majeurs:
 - Clients, produits, ventes, ...
- ◆ Sujet = faits + dimensions
 - Collecte les données utiles sur un sujet
 - Exemple: ventes
 - Synthétise une vue simple des événements à analyser
 - Exemple: Ventes (N°, produit, période, magasin,)
 - Détaille la vue selon les dimensions
 - Exemple: Produits(IDprod, description, couleur, taille, ...)
 - Magasins(IDmag, nom, ville, dept, pays)
 - Periodes(IDper, année, trimestre, mois, jour)


Schémas en étoile

- ◆ Une table de faits encadrées par N tables de dimensions



Schémas en flocons

- ◆ Raffinement du schéma étoile avec des tables normalisées par dimensions



- ◆ Avantages
 - Évite les redondances
 - Conduit aux constellations (plusieurs tables de faits à dimensions partagées)

Conception du schéma intégré

- ◆ Isoler les faits à étudier
 - Schéma des tables de faits
- ◆ Définir les dimensions
 - Axes d'analyse
- ◆ Normaliser les dimensions
 - Éclater en plusieurs tables liés par contraintes référentielles
- ◆ Intégrer l'ensemble
 - Plusieurs tables de faits partagent quelques tables de dimension (constellation d'étoiles)

Bilan conception

- ◆ Le datawarehouse regroupe, historise, résume les données de l'entreprise
- ◆ Le concepteur définit schéma exportés et intégrés
 - des choix fondamentaux !
 - Ciblage essentiel !
- ◆ Le datamart c'est plus ciblé et plus petit.
- ◆ Questions ?
 - Peut-on ajouter des données au niveau de l'entrepôt ?



3. Alimenter le DW

- ◆ ETL = Extracteur+Intégrateur
 - Extract + Transform + Load
- ◆ Extraction
 - Depuis les bases sources ou les journaux
 - Différentes techniques
 - Push = règles (triggers)
 - Pull = requêtes (queries)
 - Périodique et répétée
 - Dater ou marquer les données envoyées
 - Difficulté
 - Ne pas perturber les applications OLTP

Transformation

- ◆ Accès unifiés aux données
 - Unification des modèles
 - Traduction de fichiers, BD réseaux, annuaires en tables
 - Evolution vers XML (modèle d'échange) plus riche
 - Unification des accès
 - Rowset, SQL limité, SQL complet, ...
- ◆ Mapping plus ou moins sophistiqué
 - Unification des noms
 - Appeler pareil les mêmes choses et différemment les choses différentes
 - Application des "business rules"
 - Elimination des doubles
 - Jointure, projection, agrégation (SUM, AVG)
- ◆ Cleaning des données

Data Cleaning

- ◆ Valeurs manquantes (nulles)
 - Ignorer le tuple
 - Remplacer par une valeur fixe ou par la moyenne
- ◆ Valeurs erronées ou inconsistantes
 - Générées en présence de bruits
 - Détecter par une analyse de voisinage
 - Écart par rapport à la moyenne
 - Factorisation en groupes (outliers)
 - Remplacer par une valeur fixe ou par la moyenne
- ◆ Inspection manuelle de certaines données possible

Chargement

- ◆ Pas de mise à jour
 - Insertion de nouvelles données
 - Archivage de données anciennes
- ◆ De gros volumes
 - Périodicité parfois longue
 - Chargement en blocs (bulk load)
 - Mise à jour des index et résumés
- ◆ Problèmes
 - Cohabitation avec l'OLAP ?
 - Procédures de reprises ?

Principaux ETL (JDNet)

Business Objects ActaWorks

Issue du rachat d'Acta, cette solution se propose de rendre accessible en "quasi-temps réel" les données les plus souvent accédées. L'un des éditeurs de référence dans le domaine de l'ETL, qui s'étend sur la partie middleware en intégrant aussi les transactions.

Ascential Software DataStage XE

DataStage XE est l'offre traditionnelle d'Ardent qu'Informix a racheté début 2000 avant qu'Ascential ne la reprenne à son compte lors de sa prise d'indépendance, tandis qu'Informix partait chez IBM avec ses entrepôts de données.

Computer Associates DecisionBase

Computer Associates est plus connu pour ses offres de sécurité, de surveillance et de gestion d'infrastructures réseaux/informatiques. Mais son offre ETL s'avère assez complète y compris pour maintenir l'intégrité des métadonnées sur toute la chaîne de traitement. L'outil ETL s'appelle Vision:Pursuit.

Acta était le fournisseur historique du premier connecteur à SAP. Partenaire notamment de Siebel, Peoplesoft et JDEdwards. Interfaçage avec Cognos, Hyperion, Actuate et Brio.

Plus de 40 connecteurs natifs vers des sources de données, dont IBM/Informix, Oracle, Sybase, Teradata et IBM DB2. Package complet dédié à SAP et à la collection de modules MySAP. Partie analytique: Brio, Business Objects, SPSS et Crystal Decisions.

Connecteurs en direct pour extraire les données en temps réel depuis SAP, PeopleSoft et des systèmes mainframes. Accès à de nombreuses sources de données dont IBM/Informix, Oracle, Sybase, IBM DB2, HTML et fichiers txt.

ETI ETI.Extract

Parfois citée comme plate-forme ETL de référence par certains acteurs, mais pas ceux de la business intelligence, ETI.Extract fonctionne avec des librairies pour supporter les entrepôts de données et des plugins additionnels en prolongement d'applications précises.

Surtout connu pour son offre de portail, Hummingbird fournit également une plate-forme ETL et EAI du nom de Genio Suite, assez réputée. En outre, une offre de business intelligence classique, BI/Suite prolonge le portail. Mais il n'est pas question de CRM analytique. Mais Genio Miner agrège plus de 15 algorithmes de transformation de données les plus complètes et répandues. PowerCenter à l'échelle de l'entreprise, et PowerMart à celle du service ou du département. Informatica s'est récemment engagé sur le créneau des applications analytiques, mais l'offre ETL est indépendante.

Hummingbird Genio Suite 5

Informatica PowerCenter 5

Extraction standard depuis: fichiers plats (C et Cobol), Siebel, les SGBDR, Informix, Teradata, Oracle Financials, PeopleSoft HRMS, SAP R3 et BW... Librairies pour toutes les bases de données ci-dessous, sauf Hyperion, sur systèmes anciens et plus récents. Plugins ETI Accelerator pour les entrepôts de données: Siebel, SQL/Teradata et les middleware MQ (IBM, Essbase, MS SQL Server et IBM DB2. Prise en charge nouvelle des formats de données: XML, mainframe, SAP en natif, binaires, versions récentes des SGBDR. En EAI: Siebel, SAP, support de MQ Series. Le roadmap prévoit l'intégration prochaine à des acteurs comme Brio, Cognos et Microstrategy. Vaste de connecteurs spécifiques aux sources de données pour consolider tous les principaux entrepôts de données. Pour citer quelques acteurs du CRM analytique en vrac: Siebel, Business Objects, Oracle, Hyperion, Crystal Decisions, Brio, SAP, Cognos, Peoplesoft, Kana, Nuance, Microstrategy... ainsi que les middleware MQ pour aller plus loin.

4. Gérer l'entrepôt

- ◆ Base relationnelle
 - Support de larges volumes (qq 100 gigas à qq téras)
 - Historisation des données (fenêtres)
 - Importance des agrégats et chargements en blocs
- ◆ Base spécialisée
 - Base multidimensionnelle
 - Combinaison des deux
- ◆ Machine support parallèle
 - Multiprocesseurs
 - Mémoire partagée, cluster, bus partagé, etc.

Principaux systèmes (Jdnet)

Hyperion *Essbase*

EssBase est l'entrepôt de données multi-dimensionnel de référence sur le marché de la business intelligence. Possibilité de compléter avec l'offre analytique d'Hyperion ou des solutions tierces.

Ce n'est pas à la base de données de se connecter aux applications mais aux applications de se connecter à la base de données. Les accès vers Essbase sont nombreux. Se reporter aux autres catégories pour savoir qui accède à quelles sources.

NCR *Teradata Database*

Entrepôt de données multi-dimensionnel avec des extensions de divers types dont des formules de data mining. Réputé notamment pour ses capacités de montée en charge sous Unix et Windows 2000.

Les solutions qui accèdent à Teradata sont a priori un peu moins nombreuses que pour Hyperion Essbase, Microsoft, IBM DB2, Oracle et Sybase.

IBM *DB2/UDB, Informix XPS et Red Brick*

DB2/Universal DataBase est la base de données relationnelle d'IBM. En rachetant Informix et son activité bases de données, Big Blue a récupéré ses entrepôts de données multi-dimensionnels: XPS (datawarehouse), et Red Brick (datamart).

Même remarque que pour Hyperion, en particulier pour DB2 qui est relativement répandue. Se renseigner sur les solutions qui peuvent accéder nativement aux différents SGBD OLAP propriétaires d'Informix.

Oracle *Oracle 9i*

Dernière version de la base de données relationnelle de l'éditeur, Oracle 9i est retailée dans une optique qui approfondit les fonctions dédiées à la business intelligence. Peut également fonctionner comme entrepôt de données OLAP.

Même remarque que pour Hyperion et Microsoft, car Oracle 8i est encore très répandue.

Microsoft *SQL Server 2000*

La version la plus récente de la SGBDR (base de données relationnelle) de Microsoft. A enrichi ses fonctions OLAP avec Analysis Services. Parmi celles-ci: l'accès direct aux cubes via le web, et une extension data mining.

Même remarque que pour Hyperion. SQL Server est très répandue, mais souvent encore en version 7.0 qui peut aussi être attaquée par la plupart des solutions du commerce qui fonctionnent sous Windows

Sybase *Adaptive Server IQ*

IQ est la version déclinée de la base de données relationnelle de Sybase, pour des besoins en rapport avec la business intelligence, donc aussi le CRM analytique.

Même remarque que pour Hyperion, IBM DB2, Oracle et Microsoft

Le multidimensionnel



◆ Dimensions:

- Temps
- Géographie
- Produits
- Clients
- Canaux de ventes.....


◆ Indicateurs:

- Nombre d'unités vendues
- CA
- Coût
- Marge.....

Cube de données




Le data cube et les dimensions




Le multidimensionnel

La granularité des dimensions




Exemple

- ◆ Montant des ventes fonction de (Mois, région, Produit)




Le multidimensionnel

Granularité des dimensions :




La navigation multidimensionnelle

Projection en 2 dimensions




Coupe d'un cube



Réduction selon 1 dimension



Zoom selon une dimension




L'algèbre des cubes

- ◆ Roll up :
 - Agréger selon une dimension
 - Semaine → Mois
- ◆ Drill down :
 - Détailler selon une dimension
 - Mois → Semaine
- ◆ Slice et Dice:
 - Sélection et projection selon 1 axe
 - Mois = 04-2003 ; Projeter(Région, Produit)
- ◆ Pivot :
 - Tourne le cube pour visualiser une face
 - (Région,Produit)→(Région, Mois)

Les vues d'un cube

- ◆ Partant d'un cube 3D, il est possible d'agréger selon une dimension tournante
- ◆ On obtient un treillis de vues (calculable en SQL)



Bilan Gestion


- ♦ La modélisation multidimensionnelle est adaptée à l'analyse de données
- ♦ Le datacube est au centre du processus décisionnel
 - transformation et visualisation 3D
 - une algèbre du cube
 - De multiples techniques d'optimisation
- ♦ Questions ?
 - Combien de datacubes à partir de N variables ?



5. Implémentation

- ♦ **Multidimensional OLAP (MOLAP)**
 - implémentent les cubes comme des matrices en mémoire
- ♦ **Relational OLAP (ROLAP)**
 - implémentent les cubes comme des tables relationnelles
- ♦ **Hybrid systems (HOLAP ou MROLAP)**
 - certaines données en matrices en mémoires, d'autres en tables sur disques

ROLAP versus MOLAP



Evolution des SGBD


- ◆ Utilisation intensive des calculs d'agrégats
 - Optimisation, concrétisation
- ◆ Nouvelles fonctions de SQL
 - Fonctions agrégats
 - Rank, Moving Average, Rollup, Cube, ...
 - Fonctions statistiques:
 - Pivot, Standard déviation, Covariance, Corrélation ...

Vues Concrètes

- ◆ CREATE MATERIALIZED VIEW <Table>
(column_list) AS
SELECT ...
- ◆ La vue est pré-calculée par le SGBD
 - Pré-calcul des agrégats et jointures
- ◆ Elle est maintenue lors des mises à jour
- ◆ Les requêtes sont reformulées contre la vue d'une manière transparente pour l'utilisateur

Exemple

- ♦ Table:
Emp(#emp, job, salary)
- ♦ Définition de la vue:
CREATE MATERIALIZEDVIEW
job_avg_sal
AS select job, avg(sal) avg_sal
FROM emp
GROUP BY job;
- ♦ Interrogation de la vue:
SELECT job FROM job_avg_sal
WHERE avg_sal > 10000



Extension de SQL

♦ ROLLUP:

- `SELECT <column list>`
- `FROM <table...>`
- `GROUP BY`
`ROLLUP(column_list);`

- ♦ Crée des agrégats à $n+1$ niveaux, n étant le nombre de colonne de groupage
 - $n, n-1, n-2, \dots, 0$ colonnes

♦ CUBE:

- `SELECT <column list>`
- `FROM <table...>`
- `GROUP BY`
`CUBE(column_list);`

- ♦ Crée 2^n combinaisons d'agrégats, n étant le nombre de colonne de groupage

Exemple CUBE

Animal	Lieu	Quantite
Chien	Paris	12
Chat	Paris	18
Tortue	Rome	4
Chien	Rome	14
Chat	Naples	9
Chien	Naples	5
Tortue	Naples	1

- ◆ SELECT Animal, Lieu,
SUM(Quantite) as Quantite
FROM Animaux
GROUP BY Animal, Magasin
WITH CUBE

Animal	Lieu	Quantite
Chat	Paris	18
Chat	Naples	9
Chat	-	27
Chien	Paris	12
Chien	Naples	5
Chien	Rome	14
Chien	-	31
Tortue	Naples	1
Tortue	Rome	4
Tortue	-	5
-	-	63
-	Paris	30
-	Naples	15
-	Rome	18

Exemple ROLLUP


Animal	Lieu	Quantite
Chien	Paris	12
Chat	Paris	18
Tortue	Rome	4
Chien	Rome	14
Chat	Naples	9
Chien	Naples	5
Tortue	Naples	1

- ◆ SELECT Animal, Lieu,
SUM(Quantite) as Quantite
FROM Animaux
GROUP BY Animal, Magasin
WITH ROLLUP

Animal	Lieu	Quantite
Chat	Paris	18
Chat	Naples	9
Chat	-	27
Chien	Paris	12
Chien	Naples	5
Chien	Rome	14
Chien	-	31
Tortue	Naples	1
Tortue	Rome	4
Tortue	-	5
-	-	63

Métab-données

- ♦ Standard en émergence CWM
 - Common Warehouse Meta-model
- ♦ Basé sur le méta-modèle objet de l'OMG (MOF)
 - Constructions de base: classe (attribut, operation), association, package, type de données, contraintes
 - Extensions: métaclasse, métarelations
- ♦ Défini en UML
- ♦ Echangé en XML (XMi)



Les Packages CWM

Management

Warehouse
Process

Warehouse
Operation

Analysis

Transformation

OLAP

Data
Mining

Information
Visualization

Business
Nomenclature

Resources

Object-
Oriented
(ObjectModel)

Relational

Record-
Oriented

Multi
Dimensional

XML

Foundation

Business
Information

Data
Types

Expressions

Keys
Index

Type
Mapping

Software
Deployment

ObjectModel

(Core, Behavioral, Relationships, Instance)

Chaque package est défini en UML ...

Implémentation

Quelques outils OLAP

◆ Oracle

- OLAP API = Datacube
- Express = Analyse
- Report = Reporting

◆ Business Object

- BusinessQuery = Requêtage
- BusinessObject =
Requêtage + Analyse +
Reporting
- WebIntelligence = Datacube

◆ Cognos


- Impromptu = Reporting
- Powerplay = Datacube
- Query = Requêtage

◆ Hyperion

- ESS Base = Base MOLAP
- ESS Analysis = Analyse +
Datacube

6. Le marché du BI

BI= Business Intelligence



Data PRO Users Survey

Conclusion

Les Data Trucs

- ◆ Datawarehouse
 - entrepôt des données historisées de l'entreprise
- ◆ Datamart
 - magasin de données ciblé sur un ou plusieurs sujets
- ◆ Datamining
 - exploration des données afin de découvrir des connaissances
- ◆ Datacube
 - cube de présentation d'unités selon 3 dimensions
- ◆ Datawebhouse
 - entrepôt des données collectées sur le web