

Conception de Bases Décisionnelles

Didier DONSEZ

Université Joseph Fourier (Grenoble 1)

IMA – LSR/ADELE

`Didier.Donsez@imag.fr`

`Didier.Donsez@ieee.org`

Plan

- Bases de Données Transactionnelles
- La Modélisation Dimensionnelle
- Faits et Dimensions
- Additivité des Attributs
- Mini Dimensions
- Dimensions à évolution lente
- Tables de Faits sans faits
- Estimation de la taille d 'un entrepôt
- Conclusion et Bibliographie

Bases de Données Transactionnelles (Online Transaction Processing)

■ A quoi sert la normalisation relationnelle

- Modèle de Dépendances de Données
- But : Eviter la redondance
- Inconvénient : Analyse difficile de l'activité

■ Le Temps

- instantanée de l'activité
 - BD en changement dite BD « scintillante »
besoin de données stables pour des analyses
- représentation du passé
 - un fardeau pour les systèmes OLTP

Exercice

■ Ma table historique

- `Compte (NC, DateOp, Solde)`

■ Questions :


- Quel est le solde courant de mon client 525 ?

- ```
SELECT Solde
FROM Compte
WHERE NC=525
AND DateOp= (SELECT MAX (DateOp)
 FROM Compte
 WHERE NC=525
)
```

- Quels sont les soldes courants de mes clients ?

# Bases de Données Transactionnelles

- Inconvénient : Analyse de l'activité par un non-informaticien



Modèle d'après Kimball 97, pp XIX

# Objectifs de l'Entrepôt de Données (ou Base Décisionnelle)

- **Accessibilité des informations**
  - facile à comprendre donc à utiliser
- **Information cohérente**
  - idempotence avec le temps
  - incomplétude signalée
- **Manipulation des mesures de l'activité**
  - combinaison et séparation (tranches et dès)
- **Ensemble de données et de moyens**
  - requêtes, analyse, présentation, ...
- **Publication de données déjà servies**



# Deux mondes différents

|                           | Information    | Le Temps                 |
|---------------------------|----------------|--------------------------|
| OLTP                      | Non redondance | Vue instantanée          |
| DW<br>Entrepôt de Données | Accessibilité  | Historique de l'activité |

# La Modélisation Dimensionnelle

## ■ modélise l'activité que l'on souhaite analyser

- Modèle en Etoile
  - Fait, Dimension



## ■ Cube décisionnel


- objet simple à manipuler pour des non-informaticiens

# Requête Type

```

select p.brand, sum(fv.dollars_sold), sum(fv.units_sold)
from faitvente fv, produit p, temps t
where fv.productkey = p.productkey (contrainte de jointure)
and fv.timekey = t.timekey (contrainte de jointure)
and t.quarter = ' 1 Q 97 ' (contrainte applicative)
group by p.brand
order by p.brand

```



```

select p.brand, sum(fv.dollars), sum(fv.units)
from (faitvente fv join produit p using (productkey)) join temps t using (timekey)
where t.quarter = ' 1 Q 97 ' (contrainte applicative)
group by p.brand
order by p.brand


```

# Modèle en étoile

## Modèle en flocon (de neige)


### ■ Modèle en étoile

- Table de Fait
- Tables de Dimension (1 niveau)



### ■ Modèle en flocon de neige

- Table de Fait
- Plusieurs niveaux de Tables de Dimension



# Résister à la Normalisation

## ■ Modèle en étoile

- Taille de dimension plus grosse

## ■ Modèle en flocon

- Jointures pour reconstruire

## ■ Modèle en étoile >> Modèle en flocon

- car tables de dimension << table de fait

# Processus de Conception

- Choisir le processus à modéliser
- Choisir le grain des faits
  - niveau de détails
    - transactions individuelles
    - récapitulatifs journaliers, mensuels, ...
- Choisir les dimensions
  - typiquement, le temps, le client, le foyer, le produit, le magasin, l'agence, l'agent, le contrat, le compte...
- Choisir les mesures de fait
  - de préférence des quantités numériques additives

# Tables de Fait

## ■ Fait

- Grain de mesures de l'activité
  - chiffre d'affaire, nombre de vente, gain, nombre de transaction ...  
en général : une valeur numérique  
comptage des faits sinon
- Exemple : le Fait de Vente
  - chaque enregistrement de fait représente le total des ventes d'un produit dans un magasin dans une journée

## ■ Table de Fait

- relie les tables dites de dimension

## ■ Plusieurs Tables de Fait dans un DW

# Tables de Dimension

## ■ Membre d 'une dimension

- membre spécifique munie de caractéristiques propres

## ■ Description

- en général textuelle
- parfois discrète (ensemble limité de valeurs)
  - parfum de glace, couleur d 'habit, ...

## ■ Utilisation

- contrainte applicative
- entête de ligne (dans des tableaux)

## ■ Remarque importante et Rappel

- Tables de dimension << Table de fait

# Granularité / Finesse des Faits


## ■ Tables éparses

- hypothèse d'un monde fermé
  - s'il y a pas de fait (vente = 0\$), on ne le représente pas

## ■ Niveau de détail de représentation

- journée > heure du jour
- magasin > rayonnage

## ■ Choix de la granularité



# Clés dans l'entrepôt

## ■ Tables de dimension

- clé primaire

## ■ Tables de fait

- clé composite ou concaténée
  - clés étrangères des tables de dimension
  - utilisée dans les contraintes de jointure naturelle

## ■ Choix des clés d'une table de dimension

- Taille d'un fait et Coût des comparaisons de jointures
  - valeurs entières anonymes (4 octets)
- Clés étendues
  - 2 mêmes produits de couleurs différentes = 2 membres
  - Dimension à évolution lente

# Additivité des Attributs de Fait

## ■ Plusieurs millions de faits à résumer

- compter les faits
- additionner les mesures

## ■ Propriété d 'additivité

- Fait additif
  - additionnable suivant toutes les dimensions
- Fait semi additif
  - additionnable seulement suivant certaines dimensions
- Fait non additif
  - non additionnable quelque soit la dimension  
comptage des faits ou affichage 1 par 1

# Additivité des Attributs de Fait

## ■ Exemple

- quantité vendue, chiffre d'affaire, coût, nombre de clients, nombre d'appel ...

## ■ Fait additif

- quantité vendue, chiffre d'affaire, coût

## ■ Fait semi additif

- niveau de stock, de solde (valeurs instantanées)
  - excepté sur la dimension temps
- nombre de transaction, de client
  - excepté sur la dimension produit

## ■ Fait non additif

- ex: un attribut ratio
  - ex: marge brute =  $1 - \text{Coût/CA}$

# Mesure de Fait Semi-additive

*Nombre de Clients, Nombre de Transactions, ...*

## ■ Exemple : le nombre de clients et la dimension Produit



- Soient deux faits (même magasin, même jour)
  - (Papier essuie tout, 20 clients) et (Mouchoir, 30 clients)
- La somme du nombre de clients sur la dimension Produit n 'a pas de signification
  - car un client peut avoir acheté des mouchoirs et du papier.

## ■ sert uniquement de contrainte applicative

- nombre de clients ayant acheté des mouchoirs (par mois)

# Autre Mesure de Fait Semi-additive

## *Température patient, Niveau de Stock, ...*




# Dimension Temps

- Commune à tout entrepôt
- Relié à toute table de fait
- 2 choix d'implantation
  - Type SQL DATE
  - Calendrier + Table Temps
    - informations supplémentaires
      - événement (match de finale de coupe du monde)
      - jours fériés, vacances, période fiscale,
      - saison haute ou basse, ...

## ■ Sémantique du temps

- Validation
  - occurrence du fait
- Transaction
  - prise en compte dans l'entrepôt



# Dimension Temps

## ■ Plusieurs notions de date dans l'entrepôt

- Date de l'événement
- Date de transaction
- Date de chargement
- Date de requête

## ■ Cf SGBDs Temporels


- Temps de référence pour les requêtes
  - Quel était le nombre de clients quand il était Noël ?

Les chargements effectués après Noël ne sont pas pris en compte
- Voir Chris Date, « Introduction aux Bases de Données », 7ème édition, Chapitre 22

# Dimension Causale

## ■ dimension qui provoque le fait

- ex: la dimension Promotion est supposée avoir provoqué le Fait de Vente



# Grandes Dimensions

## ■ Nombreux membres réduire la taille des tables

- dimension Produits (300.000)
- dimension Clients (10.000.000)

## ■ Solutions

### ☹ L 'appel du Flocon de Neige

- tables de dimension secondaires (déportées)  
associée à une table de dimension
- Faible gain de place et Navigation compromise

### ☺ Mini Dimensions

- Mini dimensions démographiques pour les clients


# Mini Dimensions Démographiques

## ■ Dimension client

- nombreux enregistrements, nombreux attributs

## ■ Solutions

- ☹Flocons
- ☺Mini-Dimension
  - Combinaisons (<100000) d'intervalles de valeurs démographiques



# Dimensions à évolution lente (i)

## ■ Changement de description des membres dans les dimensions

- un client peut changer d 'adresse, se marier, ...
- un produit peut changer de noms, de formulations
  - « Tree 's » en « M&M », « Raider » en « Twix »,  
« Yaourt à la vanille en Yaourt » en « saveur Vanille »

## ■ Choix entre 3 solutions

- écrasement de l 'ancienne valeur
- versionnement
- valeur d 'origine / valeur courante

## ■ Remarque

- quand la transition n 'est pas immédiate : il reste pendant un certain temps des anciens produits en rayon
- Solution : 2 membres différents

# Dimensions à évolution lente (ii)

## ■ 3 solutions

- Ecrasement de l'ancienne valeur
  - renoncer à suivre les situations passées
  - mais correction d'informations erronées
- Versionnement
  - clé étendue d'un numéro de version
  - partitionnement automatique de l'historique
- Valeur courante / Valeur d'origine
- et Valeur courante / Valeur antérieure
  - l'ancienne valeur n'est utile que pendant un certain temps pour étudier les effets d'une transition
  - exemple: renouvellement d'une force de vente

## ■ Mini dimension à évolution lente

# Dimensions à évolution lente

## Ecrasement de l'ancienne valeur

- renoncer à suivre les situations passées
- mais correction d'informations erronées

| Temps                     |
|---------------------------|
| #T:JJ:MM:AA:Event         |
|                           |
| 1201:14:02:99:St Valentin |
|                           |

| Produit  |
|----------|
| #P:Descr |
|          |
| 66:Bague |
|          |
| 77:Fleur |
|          |

| Fait de Vente     |
|-------------------|
| #T:#C:#P:Prix     |
|                   |
| 200:100:77:100    |
|                   |
| 201:100:77:100    |
|                   |
| 202:100:77:100    |
|                   |
| 202:100:66:10000  |
|                   |
| 568:100:77:20     |
|                   |
| 1115:100:77:100   |
|                   |
| 1116:100:77:100   |
|                   |
| 1117:100:66:50000 |
|                   |
| 1200:100:77:100   |
|                   |

| Client                               |
|--------------------------------------|
| #C: #V:Nom:SitMarital                |
|                                      |
| 100:Didier: <del>Divorcé</del> Marié |
|                                      |

# Dimensions à évolution lente

## Versionnement

- clé étendue d'un numéro de version
- partitionnement automatique de l'historique

| Temps                     |
|---------------------------|
| #T:JJ:MM:AA:Event         |
|                           |
| 1201:14:02:99:St Valentin |
|                           |

| Produit  |
|----------|
| #P:Descr |
|          |
| 66:Bague |
|          |
| 77:Fleur |
|          |

| Fait de Vente       |
|---------------------|
| #T:#C:#P:Prix       |
|                     |
| 200:100:1:77:100    |
|                     |
| 201:100:1:77:100    |
|                     |
| 202:100:1:77:100    |
|                     |
| 202:100:1:66:10000  |
|                     |
|                     |
| 568:100:2:77:20     |
|                     |
|                     |
| 1115:100:3:77:100   |
|                     |
| 1116:100:3:77:100   |
|                     |
| 1117:100:3:66:50000 |
|                     |
| 1200:100:4:77:100   |
|                     |

| Client                          |
|---------------------------------|
| #C: #V:Nom:SitMarital:DateEffet |
|                                 |
| 100:1:Didier:Célibataire:10     |
|                                 |
| 100:2:Didier:Marié:203          |
|                                 |
| 100:3:Didier:Divorcé:567        |
|                                 |
| 100:4:Didier:Marié:1118         |
|                                 |

# Dimensions à évolution lente

## Valeur d 'origine / valeur courante

- l'ancienne valeur n'est utile que pendant un certain temps pour étudier les effets d'une transition

| Temps                     |
|---------------------------|
| #T:JJ:MM:AA:Event         |
|                           |
| 1201:14:02:99:St Valentin |
|                           |

| Produit  |
|----------|
| #P:Descr |
|          |
| 66:Bague |
|          |
| 77:Fleur |
|          |

| Fait de Vente     |
|-------------------|
| #T:#C:#P:Prix     |
|                   |
| 200:100:77:100    |
|                   |
| 201:100:77:100    |
|                   |
| 202:100:77:100    |
|                   |
| 202:100:66:10000  |
|                   |
| 568:100:77:20     |
|                   |
| 1115:100:77:100   |
|                   |
| 1116:100:77:100   |
|                   |
| 1117:100:66:50000 |
|                   |
| 1200:100:77:100   |
|                   |

| Client                             |
|------------------------------------|
| #C: #V:Nom:SMcour:SMorig:DateEffet |
|                                    |
| 100:Didier:Marié:Célibataire:1118  |
|                                    |
| 102:Paul:Célibataire:NULL:NULL     |
|                                    |

# Dimensions à évolution lente

## Valeur antérieure / valeur courante

- La valeur antérieure n'est utile que pendant un certain temps pour étudier les effets d'une transition

| Temps                     |
|---------------------------|
| #T:JJ:MM:AA:Event         |
|                           |
| 1201:14:02:99:St Valentin |
|                           |

| Produit  |
|----------|
| #P:Descr |
|          |
| 66:Bague |
|          |
| 77:Fleur |
|          |

| Fait de Vente     |
|-------------------|
| #T:#C:#P:Prix     |
|                   |
| 200:100:77:100    |
|                   |
| 201:100:77:100    |
|                   |
| 202:100:77:100    |
|                   |
| 202:100:66:10000  |
|                   |
| 568:100:77:20     |
|                   |
| 1115:100:77:100   |
|                   |
| 1116:100:77:100   |
|                   |
| 1117:100:66:50000 |
|                   |
| 1200:100:77:100   |
|                   |

| Client                            |
|-----------------------------------|
| #C: #V:Nom:SMcour:SMant:DateEffet |
|                                   |
| 100:Didier:Marié:Divorcé:1118     |
|                                   |
| 102:Paul:Célibataire:NULL:NULL    |
|                                   |

# Dimension Client Douteuse

- Dimension Client dans laquelle la même personne peut apparaître de nombreuses fois
  - orthographes légèrement différentes
  - attributs différents


# Dimension Dégénérée

## ■ Dimension sans attribut

- Pas de table
- Mais la clé de dimension est dans la table de fait

## ■ Exemple

- numéro de facture (invoice number),
- numéro de ticket
- ...



# Tables de Suivi d 'Evénements

## ■ souvent sans mesure

- cours, enseignant, étudiant
- hôpital, médecin, patient, diagnostic
- parties d 'un accident
- schéma de couverture

## ■ Comptage des faits

# Tables de Faits Réduites et Particularisées

## ■ Application avec des produits hétérogènes



- compte chèque, compte d'épargne, ...
- police et sinistre automobile, habitation, ...

## ■ Conception (économie de place)

- tables de fait réduite
  - tous les enregistrements de fait réduit aux mesures communes
  - table dimension réduite aux attributs communs
- 1 table particularisé de fait par produit hétérogène
  - seuls les enregistrements concernant le produit
  - 1 table de dimension par produit  
attributs particuliers

## ■ Remarque : pas de OODW pour l'instant !

# Tables de Faits Réduites et Particularisées



# Codage des Clés et des Mesures

## ■ Mesure de fait

- valeurs entières (4 octets)
- parfois plus
  - ex: PNB des USA au cent près

## ■ Clés

- valeurs entières anonymes (4 octets)
  - réduit la taille de l'enregistrement de fait
  - réduit le coût CPU des comparaison de jointure
- la correspondance clé opérationnelle et clé entrepôt est faite à l'extraction

# Estimation de la taille de l'entrepôt

## ■ Dimensionner l'entrepôt

- Choix des granularités
- Choix d'une machine/SGBD cible (benchmark)

## ■ Exemple : Supermarché

- Dimensions
  - Temps : 4 ans \* 365 jours = 1460 jours
  - Magasin : 300
  - Produit : 200000 références GENCOD (10% vendus chaque jour)
  - Promotion : un article est dans une seule condition de promotion par jour et par magasin
- Fait
  - $1460 * 300 * 20000 * 1 = 8,76$  milliards d'enregistrements
  - Nb de champs de clé = 4
  - Nb de champs de fait = 4
  - Table des Faits =  $8,76.10^9 * 8 \text{ champs} * 4 \text{ octets} = \mathbf{280 \text{ Go}}$

# Estimation de la taille de l'entrepôt

## ■ Exemple : Ligne d'article en Grande Distribution

- Temps : 3 ans \* 365 jours = 1095 jours
- CA annuel = 80 000 000 000 \$
- Montant moyen d'un article = 5 \$
- Nb de champs de clé = 4
- Nb de champs de fait = 4
- Nombre de Faits =  $3 \cdot (80 \cdot 10^9 / 5) = 48 \cdot 10^9$
- Table de Faits =  $48 \cdot 10^9 \cdot 8 \text{ champs} \cdot 4 \text{ octets} = \mathbf{1,59 \text{ To}}$

## ■ Exemple : Suivi d'appels téléphoniques

- Temps : 3 ans \* 365 jours = 1095 jours
- Nombre d'appel par jour = 100 000 000
- Nb de champs de clé = 5
- Nb de champs de fait = 3
- Table des Faits =  $1095 \cdot 10^8 \cdot 8 \text{ champs} \cdot 4 \text{ octets} = \mathbf{3,49 \text{ To}}$

## ■ Exemple : Suivi d'achats par carte de crédit

- Temps : 3 ans \* 12 mois = 36 mois
- Nombre de compte carte = 50 000 000
- Nombre moyen d'achat par mois par carte = 50
- Nb de champs de clé = 5
- Nb de champs de fait = 3
- Table des Faits =  $54 \cdot 10^9 \cdot 8 \text{ champs} \cdot 4 \text{ octets} = \mathbf{1,73 \text{ To}}$

# Conclusion

- Résister à la normalisation
- ...

# Bibliographie - Livre

- Ralph Kimball, Entrepôts de Données, Ed. Intl Thomson Pub., 1997 et 2000, ISBN 2-84180-021-0
  - la bible du concepteur 😊😊😊
  - contient un outil (StarTracker) et des bases d'exemples.
  - Son nouvel ouvrage sort en 04/2002 ([www.rkimball.com](http://www.rkimball.com))
- Rob Mattison, Data Warehousing -Strategies, Technologies and Technics, IEEE Computer Society 1996, ISBN 0-07-041034-8, 55\$
  - la méthodologie d'organisation 😊
- Jean Michel Franco, Le Data Warehouse / Le Data Mining, Eyrolles, 1997
  - un survol en français 😊

## Bibliographie - Livre

- Ralph Kimball, Laura Reeves , "Concevoir et déployer un data warehouse Guide de conduite de projet ", Ed Eyrolles
- Ralph Kimball, "The Data Warehouse Toolkit: The Complete Guide to Dimensional Modeling, 2nd Edition"
- Ralph Kimball, "The Data Webhouse Toolkit: Building the Web-Enabled Data Warehouse"