

Préparation des données



M.E.S Gestion Sàrl
Rue Louis-Favre 34
2002 Neuchâtel
☎ +41 32 729 35 00
✉ +41 32 729 35 01
contact@mesgestion.ch
www.mesgestion.ch

Auteur : Dan Noël

Date : 24.04.2009




Objectifs du module

- Comprendre les données et passer en revue les étapes principales de la préparation des données afin de maximiser la performance de la modélisation

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Determine Business Objectives <i>Background</i> <i>Business Objectives</i> <i>Business Success Criteria</i>	Collect Initial Data <i>Initial Data Collection Report</i>	Select Data <i>Rationale for Inclusion/Exclusion</i>	Select Modeling Techniques <i>Modeling Technique</i> <i>Modeling Assumptions</i>	Evaluate Results <i>Assessment of Data Mining Results w.r.t. Business Success Criteria</i> <i>Approved Models</i>	Plan Deployment <i>Deployment Plan</i>
Assess Situation <i>Inventory of Resources</i> <i>Requirements, Assumptions, and Constraints</i> <i>Risks and Contingencies</i> <i>Terminology</i> <i>Costs and Benefits</i>	Describe Data <i>Data Description Report</i>	Clean Data <i>Data Cleaning Report</i>	Generate Test Design <i>Test Design</i>	Review Process <i>Review of Process</i>	Plan Monitoring and Maintenance <i>Monitoring and Maintenance Plan</i>
Determine Data Mining Goals <i>Data Mining Goals</i> <i>Data Mining Success Criteria</i>	Explore Data <i>Data Exploration Report</i>	Construct Data <i>Derived Attributes</i> <i>Generated Records</i>	Build Model <i>Parameter Settings</i> <i>Models</i> <i>Model Descriptions</i>	Determine Next Steps <i>List of Possible Actions</i> <i>Decision</i>	Produce Final Report <i>Final Report</i> <i>Final Presentation</i>
Produce Project Plan <i>Project Plan</i> <i>Initial Assessment of Tools and Techniques</i>	Verify Data Quality <i>Data Quality Report</i>	Integrate Data <i>Merged Data</i>	Assess Model <i>Model Assessment</i> <i>Revised Parameter Settings</i>		Review Project <i>Experience</i> <i>Documentation</i>
		Format Data <i>Reformatted Data</i> <i>Dataset</i> <i>Dataset Description</i>			

La qualité des données

- Toutes les sources de données présentent des problèmes de qualité
- Les modèles de Data Mining réagissent plutôt mal à des données de mauvaises qualité
- Causes de erreurs:
 - Sources
 - Livraison
 - Extraction
 - Transformation
 - Chargement



La mauvaises qualité des données

Causes possibles

- Au niveau d'une table
 - Observations dupliquées
 - Variables clés dupliquées
 - Variable clés manquantes
- Au niveau des variables individuelles
 - Valeur manquante
 - Valeur nulle
 - Valeur positive/négative
 - Out liners
 - Valeur codées
 - Date



La mauvaise qualité des données

Corrections possibles

- Modification d'une variable
- Elimination d'une observation
- Remplacer les valeurs manquantes:
 - Une valeur à part
 - La moyenne / médiane
 - Valeur aléatoire selon la distribution
 - Une estimation basée sur la redondance des données



Le cas particulier des données « Missing »

- Un des problèmes les plus fréquent rencontré dans le cadre de projet de Data Mining
- Les données manquantes recoupent plusieurs cas de figure:
 - Champ totalement vide (white space ou null value)
 - Champ numérique avec une valeur de type caractère
 - Valeur codée pour valeur manquante (99 ou autre)

Exemples de « valeurs manquantes »

MISSING VALUES

```
SmallSampleMissing.txt - Notepad
File Edit Format Help
ID, AGE, SEX, REGION, INCOME, MARRIED, CHILDREN, CAR
ID12701, 23, MALE, INNER_CITY, 18766, YES, 1, YES
ID12702, 30, , RURAL, 9915, NO, 2, NO
ID12703, 45, , RURAL, 21881, NO, 0, YES
ID12704, 50, MALE, TOWN, , YES, 2, NO
ID12705, 41, FEMALE, INNER_CITY, , YES, 0, NO
ID12706, 20, MALE, INNER_CITY, 16688, NO, 1, NO
ID12707, 46, FEMALE, RURAL, 39068, YES, 0, YES
ID12708, 50, FEMALE, INNER_CITY, 27740, YES, 1, YES
ID12709, 42, MALE, INNER_CITY, 33584, NO, 3, YES
ID12710, 57, FEMALE, TOWN, 19621, YES, 99, YES
```

Valeurs manquantes SPSS Clementine

White space

undefined

Table (8 champs, 10 enregistrements)

	ID	AGE	SEX	REGION	INCOME	MARRIED	CHILDREN	CAR
1	ID12701	23	MALE	INNER_CITY	18766	YES	1	YES
2	ID12702	30		RURAL	9915	NO	2	NO
3	ID12703	45		RURAL	21881	NO	0	YES
4	ID12704	50	MALE	TOWN	\$null\$	YES	2	NO
5	ID12705	41	FEMALE	INNER_CITY	\$null\$	YES	0	NO
6	ID12706	20	MALE	INNER_CITY	16688	NO	1	NO
7	ID12707	46	FEMALE	RURAL	39068	YES	0	YES
8	ID12708	50	FEMALE	INNER_CITY	27740	YES	1	YES
9	ID12709	42	MALE	INNER_CITY	33584	NO	3	YES
10	ID12710	57	FEMALE	TOWN	19621	YES	99	YES

Missing code

Le nœud: QUALITE

- Cet outil de Clementine produit un rapport à propos des valeurs manquantes dans un jeu de données
- Il tient compte de tous les différents types de « valeurs manquantes » mentionnés plus tôt

Palette <OUTPUT>...




Les paramètres du nœud QUALITE

The screenshot shows the 'Qualité' dialog box with the following settings and annotations:

- Evaluer tous les champs** (selected) / **Evaluer les champs sélectionnés**
- Traiter comme valeurs non valides :**
 - ☒ **Valeurs nulles (non définies)** (Annotated: **undefined = \$ null \$**)
 - ☒ **Blanc** (Annotated: **Pas de caractères visibles**)
 - ☐ **Valeur non renseignée** (Annotated: **Code de valeur Missing**)
 - ☒ **Chaîne vide** (Annotated: **Pas de caractères ni d'espace**)
- Calculer :**
 - ☒ **Nombre d'enregistrements avec valeurs valides**
 - ☐ **Ventilation du nombre d'enregistrements avec valeurs non valides**
- Qualité** (selected) / **Sortie** / **Annotations**
- Buttons:** OK, Exécuter, Annuler, Appliquer, Réinitialiser

Sortie avec uniquement option « undefined »




The screenshot shows a window titled "Qualité de [8 champs]" with a menu bar containing "Fichier", "Edition", and "Générer". Below the menu is a toolbar with icons for file operations and a help icon. The main area contains a table with three columns: "Champ", "% terminé(s)", and "Enregistrements valides". The table lists 8 fields: ID, AGE, SEX, REGION, INCOME, MARRIED, CHILDREN, and CAR. The "INCOME" row is highlighted with a red border, showing 80% completion and 8 valid records. At the bottom, there are two tabs: "Qualité" (selected) and "Annotations".

Champ	% terminé(s)	Enregistrements valides
ID	100	10
AGE	100	10
SEX	100	10
REGION	100	10
INCOME	80	8
MARRIED	100	10
CHILDREN	100	10
CAR	100	10

Seule la variable INCOME montre des valeurs manquantes alors que l'analyse de la table de base nous a montré d'autres problèmes de qualité des données...

Définir des codes de valeurs manquantes

- Cette opération doit être réalisée depuis l'onglet TYPE dans le nœud SOURCE de données



On indique à SPSS Clementine quelles valeurs (codes) dans un champ doivent être considérées comme manquantes

Exemple déclaration pour la variable CHILDREN

CHILDREN valeurs

Type : Intervalle Stockage : Entier

Valeurs :
☐ Lire à partir des données ☐ Transférer
☒ Indiquer les valeurs

Inférieur : 0
Supérieur : 99

Etiquettes...

☐ Etendre les valeurs à partir des données

Vérifier les valeurs : Aucun

☒ Définir les blancs

Valeurs manquantes
99

☐ Intervalle à :
☒ Valeur nulle ☐ Blanc


Description :

OK Annuler Aide

99 est un code souvent utilisé
pour indiquer des valeurs
manquantes

Autres problèmes de qualité des données

- 100% des problèmes de qualité ne concernent pas uniquement les « valeurs manquantes »
- On peut également rencontrer des erreurs de saisie, des valeurs aberrantes ou des irrégularités statistiques (distribution, ...)




Le nœud AUDIT de données

- Cet outil de Clementine permet d'obtenir rapidement un résumé statistique et graphique (distribution) de l'ensemble des variables d'une source de données

Palette <OUTPUT>...



Les paramètres du nœud AUDIT



Choix de indicateurs à calculer pour le résumé par variable

Exemple de l'output du nœud AUDIT

Audit des données de [12 champs]

Champ	Graphiques	Type	Min	Max	Moyenne	Ecart-type	Asymétrie	Unique	Valide
ID	* Trop de valeurs	Ensem...	--	--	--	--	--	250	514
AGE		Intervalle	18	50	31.805	9.599	0.254	--	513
INCOME		Intervalle	15045	59193	25556.171	8723.647	1.609	--	514
GENDER		Ensem...	--	--	--	--	--	3	514
MARITAL		Ensem...	--	--	--	--	--	3	514
NUMKIDS		Intervalle	0	4	1.411	1.145	0.612	--	514
NUMCARDS		Intervalle	0	6	2.463	1.884	0.606	--	514
HOWPAID		Booléen	--	--	--	--	--	2	514
MORTGAGE		Booléen	--	--	--	--	--	2	514
STORECAR		Intervalle	0	5	2.521	1.377	0.383	--	514
LOANS		Intervalle	0	3	1.346	0.840	0.284	--	514
RISK		Ensem...	--	--	--	--	--	3	514


Audit Annotations

Analyse préliminaire: quelques exemples

- S'agissant d'un fichier de demandes de crédit, que pensez-vous des informations suivantes?


Variable AGE:

Min= 11 Max= 50



Analyse préliminaire: quelques exemples

- S'agissant d'un fichier de demandes de crédit, que pensez-vous des informations suivantes?



Opérations sur les données

- L'analyse de la qualité des informations impose dans la majorité des manipulations des données
 - Nettoyage des données
 - Agrégation de variables
- Plusieurs éléments de Clementine sont dédiés à ces « transformations »
 - Niveau des enregistrements
 - Niveau des variables

Manipulation des données dans SPSS Clementine

- Au niveau des enregistrements



- Au niveau des variables




L'outil SELECT

- Permet d'effectuer une sélection des données du flux (inclure ou exclure)
- Fonctionne sur la base de critère de sélection déterminés par l'utilisateur

Palette <OPS SUR LIGNES>...




Paramètres du nœud SELECT



Les choix des critères: le générateur d'expressions CLEM

Opérateurs et fonctions

Variables à disposition



Quelques expressions CLEM

+	Add	>	greater than
-	Subtract	<	less than
*	Multiply	>=	greater than or equals
/	Divide	<=	less than or equals
**	Raise to the power	=	equal to
div	return the quotient	/=	not equal to
rem	return the remainder on dividing	mod	return the modulus
>>	Joins string expressions together (concatenation)		

round	rounds to the nearest integer away from 0.5
abs	gives the absolute value
sqrt	Takes the square root
log	Natural logarithm
exp	Raises e to the power of
sin/cos	Trigonometric functions
min / max	Returns the minimum or maximum of its arguments
substring(start, length, string)	Returns part of a string, from start for a specified length

Exercice

Utiliser le nœud SELECT

- Utiliser l'outil SELECT pour déterminer si le facteur REVENU (avec une borne $<$ ou $>$ à 20'000) a une influence sur le risque?
- **Fichier de base:** *SmallSampleComma.txt*

L'outil FILTRE

- L'élément FILTRE de Clementine permet:
 - D'exclure des variables du périmètre d'analyse
 - Renommer les variables à utiliser pour l'analyse


Palette <OPS SUR CHAMPS>...



Paramètres du nœud FILTRE

Cliquer sur la flèche pour exclure la variable correspondante

Bouton droit de la souris pour renommer



L'outil TRIER

- Cet élément de Clementine permet de trier les enregistrements soit par ordre croissant ou décroissant

Palette <OPS SUR LIGNES>...



Paramètres du nœud TRIER

Choix de l'ordre du tri

Ajouter des critères de tris

Trier

Trier par :

Champ	Ordre
INCOME	▲ Croissant

Ordre de tri par défaut : ☒ Croissant ☐ Décroissant


Paramètres Annotations

OK Annuler Appliquer Réinitialiser

L'outil RE-TRIER


- A ne pas confondre avec l'outil précédent
- Permet de changer l'ordre d'apparence des variables dans les tables

Palette <OPS SUR CHAMPS>...



Paramètres du nœud RE-TRIER

Choix des variables




The screenshot shows the 'Re-trier' (Re-sort) dialog box. A red arrow points from the text 'Choix des variables' to a button in the top right corner of the dialog, which is used to select variables. The dialog has a title bar with a yellow diamond icon and the text 'Re-trier'. Below the title bar is a search field with a magnifying glass icon. The main area contains two radio buttons: 'Ordre personnalisé' (selected) and 'Tri automatique'. Below these are three dropdown menus for 'Type', 'Nom', and 'Stockage'. A table lists variables with their types and storage methods. The table has three columns: 'Type', 'Champ', and 'Stockage'. The variables listed are INCOME, NUMCARDS, NUMKIDS, and MARITAL. The 'Type' column has icons for each variable. The 'Stockage' column shows 'Entier' for INCOME, NUMCARDS, and NUMKIDS, and 'Chaîne' for MARITAL. Below the table is a button 'Effacer les éléments non utilisés'. At the bottom, there are buttons for 'OK', 'Annuler', 'Appliquer', and 'Réinitialiser'. A note at the bottom states: 'Remarque : les champs ajoutés en aval de ce noeud ne sont pas réorganisés.'

Type	Champ	Stockage
	INCOME	Entier
	NUMCARDS	Entier
	NUMKIDS	Entier
	MARITAL	Chaîne
[autres champs]		

L'outil CALCULER

- Outil très important de Clementine permettant de créer des variables avec des règles de calculs personnalisées

Palette <OPS SUR CHAMPS>...



Paramètres du nœud CALCULER

The screenshot shows the 'Calculer' dialog box with the following elements and annotations:

- Nom de la nouvelle variable**: Points to the text field containing 'Calculer1'.
- Type de calcul à appliquer**: Points to the dropdown menu showing 'Formule'.
- Calcul à appliquer**: Points to the 'Appliquer' button.

The dialog box contains the following fields and controls:

- Calculer en tant que :** Formule
- Mode :** ☒ Simple ☐ Multiple
- Calculer champ :** Calculer1
- Calculer en tant que :** Formule
- Type de champ :** ⚡ <Valeur par défaut>
- Formule :** [Empty text area]
- Buttons:** OK, Annuler, Appliquer, Réinitialiser

Types de calculs possibles

Formule	Variable résultante est le résultat d'une expression CLEM
Booléen	Résultat est un FLAG de type True/False
Ensemble	La nouvelle variable est un groupe prédéfini
Etat	Le nouveau champ représente 1 état parmi 2 possibles. Le choix dépend d'une condition
Comptage	Le nouveau champ est le résultat d'un comptage
Conditionnel	La nouvelle variable est le résultat de 1 ou 2 expressions dépendant de la valeur d'une condition

CALCULER

Utilisation de formules

Calculer

Calculer en tant que : Formule

Mode : ☒ Simple ☐ Multiple

Calculer champ :
Total des dettes

Calculer en tant que : Formule

Type de champ : <Valeur par défaut>

Formule :
NUMCARDS + STORECAR + LOANS

Paramètres Annotations

OK Annuler Appliquer Réinitialiser

Formule créée avec le générateur d'expression CLM

CALCULER:

Les fonctions booléennes

The screenshot shows the 'Calculer' (Calculate) dialog box. It has a title bar with a yellow diamond icon and a close button. Below the title bar is a text field for the calculation name, currently containing 'Calculer en tant que : Booléen'. Below this is a 'Mode' section with two radio buttons: 'Simple' (selected) and 'Multiple'. The 'Calculer champ :' (Calculate field) section has a text field containing 'Enfant O/N'. The 'Calculer en tant que :' (Calculate as) section has a dropdown menu set to 'Booléen'. The 'Type de champ :' (Field type) section has a dropdown menu set to 'Booléen'. The 'Valeur vraie :' (True value) section has a text field containing 'OUI'. The 'Valeur fausse :' (False value) section has a text field containing 'NON'. The 'Vrai quand :' (True when) section has a text field containing 'NUMKIDS > 0'. At the bottom are two tabs: 'Paramètres' (selected) and 'Annotations'. Below the tabs are four buttons: 'OK', 'Annuler', 'Appliquer', and 'Réinitialiser'. Red annotations are present: a red box labeled 'Valeur si: vrai ou faux' with arrows pointing to the 'Valeur vraie' and 'Valeur fausse' fields; and a red box labeled 'Condition(s)' with an arrow pointing to the 'Vrai quand' field.

Calculer

Calculer en tant que : Booléen

Mode : ☒ Simple ☐ Multiple

Calculer champ :
Enfant O/N

Calculer en tant que : Booléen

Type de champ : Booléen

Valeur vraie : OUI

Valeur fausse : NON

Vrai quand : NUMKIDS > 0

Paramètres Annotations

OK Annuler Appliquer Réinitialiser

Valeur si: vrai ou faux

Condition(s)

CALCULER

Utiliser des ensembles

Calculer

Calculer en tant que : Ensemble

Mode : ☒ Simple ☐ Multiple

Calculer champ :
Groupe de revenus

Calculer en tant que : **Ensemble**

Type de champ : **Ensemble** Valeur par défaut : défaut

Définir le champ sur	Si cette condition est vraie
LOW	INCOME < 20000
MEDIUM	INCOME >= 20000 and INCOME < 35000
HIGH	INCOME >= 35000

Paramètres Annotations

OK Annuler Appliquer Réinitialiser

CALCULER

Les fonctions conditionnelles

IF
THEN
ELSE

Calculer

Calculer en tant que : Conditionnel

Mode : ☒ Simple ☐ Multiple

Calculer champ :
Ratio1

Calculer en tant que : Conditionnel

Type de champ : <Valeur par défaut>

Si :
STORECAR > 0

Donc :
INCOME / STORECAR

Sinon :
INCOME


Paramètres Annotations

OK Annuler Appliquer Réinitialiser

L'outil REMPLACER

- Cet outil de Clementine (très utile pour traiter les valeurs manquantes) permet de remplacer la valeur d'une variable dans les enregistrements selon que celle-ci soit:
 - Dans tous les cas (toujours)
 - Une condition
 - Valeur nulle
 - Valeur non-renseignée

Palette <OPS SUR CHAMPS>...



Paramètres du nœud REMPLACER

The screenshot shows the 'Remplacer' (Replace) dialog box with the following fields and annotations:

- Variable à traiter**: Points to the top input field.
- Type de remplacement**: Points to the 'Renseigner les champs' section, which contains a list with 'NUMKIDS' highlighted.
- Valeurs nulles et non renseignées**: Points to the 'Remplacer' dropdown menu.
- Valeur de substitution**: Points to the 'Remplacer par' input field, which contains the value '99'.

The dialog box also includes a 'Condition' field with the text '@BLANK(@FIELD)', a 'Paramètres' tab, and buttons for 'OK', 'Annuler', 'Appliquer', and 'Réinitialiser'.

Outil RECODER

- Permet de re-classifier les valeurs d'une variable de type Ensemble ou Booléen
- Clementine peut soit remplacer celle de la table de base ou créer une nouvelle variable de stockage

Paramètres du nœud RECODER

The screenshot shows the 'Recoder' dialog box with the following settings and annotations:

- Mode :** ☒ Simple ☐ Multiple
- Recoder dans :** ☒ Nouveau champ ☐ Champ existant (Annotated: **Remplacer ou nouveau champ**)
- Recoder le champ :** RISK
- Nouveau nom de champ :** RISK2
- Annotations :** Includes buttons for 'Ajouter', 'Copier', and 'Auto...'
- Table of values:**

Valeur d'origine	Nouvelle valeur
bad loss	bad
bad profit	bad
good risk	good

(Annotated: **Valeurs actuelles** for the first column and **Nouvelles valeurs** for the second column)
- A utiliser pour les valeurs non spécifiées :** ☒ Valeur d'origine ☐ Valeur par défaut (undef)
- Tabs:** Paramètres (selected), Annotations
- Buttons:** OK, Annuler, Appliquer, Réinitialiser

Générer automatiquement des nœuds

- Clementine offre la possibilité de créer plus facilement certains nœuds notamment des sélection en utilisant des autres nœuds de l'application...
- Exemples
 - A partir d'un histogramme
 - A partir du nœud qualité des données
 - Etc...

L'outil spécial V.GLOBALES

- Ce nœud permet de calculer des indicateurs globaux sur la base des variables disponibles
- Celles-ci peuvent être ensuite réutilisées dans le flux Clementine au travers du générateur d'expressions

Palette <Sortie>...



Paramètres du nœud V:GLOBALES

The screenshot shows the 'V. globales' dialog box. A red box highlights the 'age' variable in the 'Champ' column, with an annotation 'Variable(s) à traiter' pointing to it. Another red box highlights the row of statistical indicators (Moyenne, Somme, Minimum, Maximum, Ecart-type) for the 'age' variable, with an annotation 'Indicateurs globaux à calculer' pointing to it. The dialog also includes checkboxes for default operations, a section for execution options, and tabs for 'Paramètres' and 'Annotations'.

Champ	Moyenne	Somme	Minimum	Maximum	Ecart-type
age	☒	☒	☒	☒	☒

Opération(s) par défaut : ☒ Moyenne ☒ Somme ☒ Minimum ☒ Maximum ☒ Ecart-type

☒ Effacer toutes les valeurs globales avant l'exécution

☐ Afficher un aperçu des valeurs globales créées avant l'exécution

Paramètres Annotations

OK Exécuter Annuler Appliquer Réinitialiser