

République Algérienne Démocratique et Populaire
Ministère de l'enseignement Supérieur et de la Recherche Scientifique
Université Mouloud Mammeri de Tizi-Ouzou



Faculté De Génie électrique Et Informatique
DEPARTEMENT D'AUTOMATIQUE

Mémoire de Fin d'Etude
De MASTER ACADEMIQUE
Spécialité : Commande des systèmes

Présenté Par
KHELLOUT SIHAM
LAKHDARI HAKIMA

Mémoire dirigé par DORBANE FARIDA

Thème
Etude et application du réseau ELM-LRF en
classification des images

Mémoire soutenu publiquement le 12/07/2017 devant le jury composé de :

M^{me} ALKAMA Sadia
MCA, U.M.M.T.O, présidente
M^{me} CHILALI Ouardia
M.A.A, U.M.M.T.O, Examineur
M^{me} AIT AIDER Malika
M.A.A U.M.M.T.O, Examineur

Remerciements

Notre remerciement s'adresse en premier lieu à Allah le tout puissant pour la volonté, la santé et la patience qu'il nous a donné durant toutes ces longues années.

Ainsi, nous tenons également à exprimer nos vifs remerciements à notre promotrice Melle DORBANE Farida qui nous avoir apporté une aide précieuse. Pour l'intéressante documentation qu'elle à mis à notre disposition, Nous lui exprimons notre gratitude pour sa grande disponibilité ainsi que pour sa compréhension et les encouragements qu'elle nous a apportés...

Nous remerciement les plus vif s'adresse aussi a, la présidente de jury et les membres de jury d'avoir accepté d'examiner et d'évaluer notre travail.

Enfin, nous tenons à exprimer notre reconnaissance à tous nos amis et collègues pour le soutien moral et matériel...

Siham et Hakima



*A la femme la plus courageuse, sensible,
généreuse, la plus belle à mes yeux, à celle qui a su me
donner amour et joie de vivre, à celle qui a toujours
montrée affection et compréhension à mon égard, ma
mère que j'aime.*

*A l'homme de courage et de force à celui qui a toujours
été présent, qui m'a appris les vraies valeurs de la vie à celui
qui m'a soutenu en toutes circonstances, mon père que
j'aime.*

*A ceux qui m'ont donné joie et bonheur, amour, mes
frères : Sofiane, Samir, Kamel, belaid, Karim et ma sœur :
Samira et son mari Salem et leur adorable Idir.*

*A ceux que j'ai eu la chance de connaître, dans les
meilleurs et pires moments de ma vie, à mes amis les plus
fidèles, et à mon binôme Siham.*

*A tous ceux que j'aime, à tous ceux qui m'aiment, à
toute la famille Lakhdari et Khellout je dédie ce modeste
travail.*

Hakima





*A qui puis-je dédier cet humble travail si ce n'est
À mes très cher Parents, dont le sacrifice, la tendresse,
l'amour, la patience, le soutien, l'aide et les encouragements sont
l'essence de ma réussite. Sans eux, je ne serais pas ce que je suis
aujourd'hui.*

*Je dédie ce travail aussi :
À ma sœur Naima et son mari Mouloud et leur fils Rayane.*

*À ma sœur Yasmina et son mari Lyes et leurs filles Nour El Houda
et Maryem.*

À mes très chères sœurs Nawal et Karima.

À toute ma famille.

À mes amis « Nawal, Ourida, Souhila et Souad ».

*À mon binôme Hakima pour tous les moments de joie et de peine
qu'on a passée ensemble, à sa famille aussi.*

*ET à tous ceux qui m'ont aidé de près ou de loin à
accomplir ce travail.*

SIHAM



Liste des abréviations

- **ART** = Adaptive Resonance Theory.
- **BP** = Back propagation.
- **CNN** = convolutif neural network.
- **ELM** = Extreme Learning machine.
- **MLP** = perceptron multicouche.
- **SLFN** = Single hidden layer feedforward networks with random hidden nodes.
- **ELM-LRF** = Local Receptive Fields based Extreme Learning Machine.

Liste des figures

Figure I.1 : le neurone biologique	3
Figure I.2 : Modèle de neurone formel	3
Figure I.3 : l'allure de fonction tangente hyperbolique	5
Figure I.4 : l'allure de fonction gaussienne	5
Figure I.5 : l'allure de fonction seuil	5
Figure I.6 : l'allure de fonction sigmoïde	6
Figure I.7 : Schéma de Perceptron	7
Figure I.8: Réseau multicouche	8
Figure I.9: Réseau ART.....	8
Figure I.10: connexions entre neurones	9
Figure I.11: exemple de réseau multicouche	11
Figure II.1: Les différentes méthodes de classification	17
Figure II.2: Architecture des réseaux de neurones a convolution.....	19
Figure II.3: Architecture d'ELM.....	20
Figure II.4: Architecture d'ELM-LRF	23
Figure III.1: les 11 images correspondantes à un individu	28
Figure III.2: quelques exemples d'objets de la base ALOI	29
Figure III.3: les images d'un objet de la base ALOI avec certains angles de rotation	29
Figure III.4: les objets de la base ALOI très similaires	30
Figure III.5: les images sélectionnées pour l'apprentissage.....	31
Figure III.6: les images sélectionnées pour le test	31
Figure III.7: Exemple des images d'un objet de la 1 ^{ère} partition : (a) apprentissage, (b) test	32
Figure III.8: Exemple des images d'un objet de la 2 ^{ème} partition : (c) apprentissage, (d) test	32

Figure III.9: Exemple des images d'un objet de la 3^{ème} partition : (e) apprentissage,
(f) test 33

Figure III.10: confusion entre les objets de deux classes étiquetées différemment .. 39

Liste des tableaux

Tableau I.1 : la relation entre le neurone biologique et le neurone formel.....	4
Tableau III.1 : les différentes partitions de la base ALOI.....	30
Tableau III.2: la classification avec une résolution 0.5 (image de 124x140 pixels).....	32
Tableau III.3 : la classification avec une résolution 0.2 (image de 49x46 pixels).....	33
Tableau III.4 : la classification avec une résolution 0.1 (image de 25x32 pixels).....	34
Tableau III.5 : Résultats classification en utilisant la 1 ^{ère} partition.....	35
Tableau III.6: Résultats classification en utilisant la 2 ^{ème} partition	36
Tableau III.7 : Résultats classification en utilisant la 3 ^{ème} partition	37
Tableau III.8 : Résultats classification en utilisant la 4 ^{ème} partition	38
Tableau III.9: La taille de vecteur de caractéristiques	39

Sommaire

Liste des abréviations

Liste des figures

Liste des tableaux

Introduction générale.....1

Chapitre I : Introduction aux réseaux de neurones

I.1.Introduction..... 2

I.2.Historique..... 2

I.3.Le neurone biologique 3

I.4.Le neurone formel..... 3

I.4.1.Les fonctions d'activation..... 4

I.5.Les réseaux de neurones 6

I.6.Modèles de réseaux de neurones 6

I.6.1.Réseaux de neurones non bouclé 6

I.6.1.1. Perceptron 7

I.6.1.2.Réseaux multicouches..... 7

I.6.2.Réseaux de neurones bouclés..... 8

I.6.2.1 Réseau ART (Adaptative Resonance Theory) 8

I.7.Apprentissage des réseaux de neurones..... 9

I.7.1.Apprentissage supervisé..... 9

I.7.2.Apprentissage non supervisé..... 9

I.7.3.Apprentissage par renforcement 9

I.8.Règles d'apprentissage..... 9

I.8.1.Règle de Hebb..... 9

I.8.2.Règle de Widrow-Hoff..... 10

I.8.3.Règle de Rosenblatt 10

I.8.4. Règle de rétro-propagation..... 10

I.9.Mise en œuvre des réseaux de neurones..... 13

I.10.Propriétés et limites des réseaux de neurones..... 13

I.10.1.Propriétés des réseaux de neurones..... 13

I.10.2. Limites des réseaux de neurones..... 14

I.11.Domains d'application des réseaux de neurones	14
I.12.Conclusion	15

Chapitre II: Réseau ELM-LRF(Extreme learning machine-local receptif field)

II.1.Introduction.....	16
II .2.Classification de données	16
II.3.Machine d'apprentissage extrême à champs récepteurs locaux (ELM-LRF)	18
II.3.1.Les réseaux de neurones à convolution	18
II.3.1.1. Architecture des réseaux de neurones convolutifs (CNN).....	19
II.3.2. Réseau de neurones à apprentissage machine extrême (ELM).....	19
II.3.2.1.Algorithme ELM.....	21
II.3.2.2.Caractéristiques d'ELM	21
II.4.Architecture d'ELM-LRF	22
II.4.1.Les champs récepteurs locaux	23
II.4.2.La structure de pooling	24
II.4.3.Poids de sortie β	25
II.5 Algorithme ELM-LRF.....	25
II.6 Différence entre l'ELM-LRF et les réseaux de neurones à convolution ...	26
II.7 Conclusion	26

Chapitre III : Evaluation du réseau ELM-LRF en classification des images

III.1.Introduction	28
III.2.Présentation des bases d'images	28
III.2.1.Base de données Yalefaces.....	28
III.2.2 Base d'images ALOI	29
III.3.Tests et résultats	30
III.3.1. Tests.....	30
III.3.1.1.Préparation de données.....	30
III.3.2. Résultats et interprétation	33
III.3.2.1. Résultats de la classification de la base Yalefaces	33
III.3.2.2 Résultats de la classification de la base ALOI	35

III.3.3 interprétation des résultats des deux bases ALOI.....	38
III.3.3.1 Influence des taux d'exemples d'apprentissage	38
III.3.3.2 Influence du nombre de cartes.....	39
III.3.3.3 Influence de la taille du masque de convolution	40
III.3.3.4 Influence de la taille de masque de pooling	40
III.4 Conclusion.....	40
Conclusion général.....	41

Introduction générale

Les réseaux de neurones artificiels sont des constructions abstraites simulant l'activité du réseau de neurones biologique. Ils sont utilisés en apprentissage pour construire des modèles, à partir des données existantes, dans le but d'effectuer des prédictions sur de nouvelles données. Les réseaux de neurones ont fait leurs preuves dans plusieurs applications, en particulier la classification des images. Les réseaux de neurones de type perceptron multicouche *feedforward* sont les plus utilisés en classification qui sont modélisés, en général, par la rétro-propagation. Le temps d'apprentissage relativement long et la présence des minimas locaux font partie des limites de ce type de réseaux de neurones. Pour y remédier, Huang a proposé le réseau ELM (*Extreme Learning Machine*).

Le réseau ELM est un réseau d'architecture très simple de type *feedforward* à une seule couche cachée, les poids d'entrée sont assignés de façon aléatoire et restent constants, seuls les poids de sortie sont calculés de manière analytique en utilisant la méthode des moindres carrés. Par conséquent, la phase d'apprentissage nécessite un temps de calcul très court, en plus la bonne capacité de généralisation. Le réseau ELM est utilisé dans plusieurs domaines tels que la classification des données, mais malheureusement ce n'est pas le cas pour la classification des images. Pour surmonter ce problème, Huang a combiné le concept des réseaux de neurones à convolution et l'ELM, et a proposé ELM-LRF (*Extreme Learning Machine-Local Receptive Field*). La couche d'entrée et la couche cachée dans ELM-LRF sont localement connectées, ce qui permet au réseau de considérer les structures locales de l'image. Ce dernier a montré de bonnes performances dans le domaine de traitement d'images : temps d'apprentissage rapide, l'exploitation d'image brute, et peu de paramètres à régler.

Dans ce travail, nous avons étudié le réseau ELM ainsi son extension ELM-LRF. Pour évaluer ce réseau sur la classification des images, nous l'avons testé sur deux bases différentes. La base des images Yalefaces, en niveau de gris, pour la reconnaissance de personnes et la base des images ALOI, en couleur, de 1000 objets.

Notre travail est organisé en trois chapitres :

Le premier chapitre décrit les notions de base pour la compréhension des réseaux de neurones. Le second chapitre expose les différentes méthodes de classification des images, et les algorithmes d'apprentissage des réseaux de neurones, parmi eux l'algorithme ELM, sa représentation, son architecture et sa variante ELM-LRF développée en vue d'amélioration. Le dernier chapitre est consacré aux différents tests et résultats. À la fin nous terminons par une conclusion générale.

I.1.Introduction

Les réseaux de neurones artificiels sont inspirés du comportement du cerveau humain permettent de créer de l'intelligence artificielle, sont des réseaux connectés de processus élémentaires fonctionnent en parallèle, chaque processus calcul une sortie unique sur la base d'information qu'il reçoit. Ce chapitre a pour but de donner les notions de base pour la compréhension des réseaux de neurones, ces différents types, les fonctions d'activation, l'apprentissage (supervisé et non supervisé), les différents algorithmes d'apprentissage, les propriétés des réseaux de neurones et leurs domaines d'application.

I.2.Historique

Dés 1943, Mac Culloch et Pitts ont proposé des neurones formels mimant les neurones biologique et capable de mémoriser des fonctions simples. Les réseaux de neurones artificiels réalisés à partir de ce type de neurones sont ainsi inspirés du système nerveux, ils sont conçus pour reproduire certaines caractéristiques des mémoires biologiques par le fait qu'ils sont capables d'apprendre, de mémoriser l'information. En 1949, HEBB a publié un ouvrage sur l'organisation de comportement et a proposé une explication sur l'apprentissage. La règle de HEBB est toujours utilisée dans les techniques d'apprentissage des réseaux de neurones . En 1958, F. Rosenblatt, Widrow et Hoff ont proposé le première modèle opérationnel « le perceptron », inspiré du modèle visuel et capable d'apprendre, en mettant en œuvre les idées de HEBB et Mac Culloch et Pitts. Il possède deux couches de neurones : une couche de perceptron qui peut réaliser des fonctions logiques, arithmétiques et symboliques complexes et de résoudre que des problèmes linéairement séparable, et une couche liée à la prise de décision. C'est le premier système capable d'apprendre par expérience [1]. Dans la même période, Widrow développe le modèle Adaline, ce réseau est la base des réseaux multicouches. En 1969, M. MINSKY et PAPERT publient une critique des propriétés du perceptron (les limites de perceptron). En 1972, T.Kohonen présente ses travaux sur les mémoires associatives et propose des applications à la reconnaissance de formes, et Les travaux de Hopfield en 1982 ont montrés que des réseaux de neurones artificiels étaient capable de résoudre des problèmes d'optimisation [2].

Aujourd'hui les réseaux de neurones sont utilisés dans de nombreux domaines, en raison de leurs propriétés en particulier, leur capacité d'apprentissage, et qu'ils soient des systèmes dynamique.

I.3. Le neurone biologique

Le cerveau est l'organe de commande le plus complexe et le plus inconnu de la biologie de l'homme ou de l'animal. Les cellules nerveuses appelées neurones sont les éléments de base du système nerveux [3]. Le cerveau humain contient environ 10^{11} neurones, chacun relié en moyenne à 10^5 autres qui assurent l'émission et la réception des signaux engendrés par les neurones eux-mêmes [4]. Chaque neurone biologique est constitué de trois parties principales se sont : les dendrites, le corps cellulaire et l'axone (voir figure 1.1).




Figure I.1 : le neurone biologique

Le corps cellulaire : appelé aussi (soma) participe aux réactions électrochimiques avec le noyau. Ce dernier provoque l'envoi d'un influx nerveux électrique à travers l'axone.

Dendrites : sont des prolongements courts selon leur longueur et leur perméabilité, ce sont les entrées principales des neurones qui captent l'information venant d'autres neurones.

L'axone : c'est un prolongement long et unique de corps cellulaires, transport l'influx nerveux vers les synapses. Ces derniers transmettent l'influx nerveux provenant de l'axone vers d'autres cellules.

I.4. Le neurone formel

Inspiré de neurone biologique, le neurone formel (voir figure I.2) est une fonction paramétrée, non linéaire, de plusieurs variables. La valeur de la fonction est disponible en sortie de neurone [5].




Figure I.2 : Modèle de neurone formel

En règle générale, le calcul de la valeur de cette fonction peut se faire en 2 étapes :

- Une combinaison linéaire des entrées, en utilisant la relation suivante :

$$V = \sum_{i=1}^n W_i \cdot X_i \quad (I.1)$$

- Et la sortie du neurone est donnée par la relation suivante:

$$Y = F(V) = F\left(\sum_{i=1}^n W_i \cdot X_i\right) \quad (I.2)$$

Tel que :

$[X_1, \dots, X_n]$: représente les entrées de i neurones.

$[W_1, \dots, W_n]$: représente les poids synaptique.

V : est la somme pondérée.

F : est la fonction d'activation.

Y : est la sortie d'un neurone.

Correspondance neurone biologique/formel : On peut résumer la modélisation du neurone formel à partir du neurone biologique dans le tableau suivant [6] :

Neurone biologique	Neurone formel
synapses	Poids de connexion
axone	Signal de sortie
Dendrite	Signal d'entrée
Corps cellulaire	Fonction d'activation

Tableau I.1 : la relation entre le neurone biologique et le neurone formel

I.4.1. Les fonctions d'activation

La fonction d'activation représente l'un des paramètres les plus importants des réseaux de neurones. Elle permet de définir l'état interne de neurones en fonction de son entrée, l'état des neurones peut être à valeurs binaires ou réelles et la fonction d'activation peut varier suivant le type du réseau et le modèle du réseau à étudier.

La fonction d'activation est caractérisée par :

- Sa monotonie : généralement monotone croissante.
- Son seuillage : possède une valeur au dessous de laquelle sa valeur est négligeable.
- Sa saturation : elle possède une valeur maximale au-dessus de laquelle sa valeur de réponse est essentiellement fixe, ceci permet d'éviter de propager de grandes valeurs dans le réseau.

Il existe de nombreuses formes possibles pour la fonction d'activation [7], dont nous citons :

- **Fonction tangente hyperbolique :**

$$F(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (\text{I.3})$$




Figure I.3: l'allure de fonction tangente hyperbolique

- **Function Gaussienne:**

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (\text{I.4})$$




Figure I.4: l'allure de fonction gaussienne

- **Function seuil:**

$$F(x) = \begin{cases} 1 & \text{si } x \geq 0 \\ 0 & \text{autrement} \end{cases} \quad (\text{I.5})$$




Figure I.5: l'allure de fonction seuil

- **Function sigmoïde :**

$$F(x) = \frac{1}{1+e^{-x}} \quad (I.6)$$




Figure I.6: l'allure de fonction sigmoïde

La fonction sigmoïde est la plus utilisée car elle est continue et différentiable, en plus, elle introduit de la non-linéarité. Elle possède une propriété simple permet d'accélérer le calcul de sa dérivée, ce qui réduit le temps de calcul nécessaire lors de l'apprentissage du réseau de neurones. Les valeurs de la fonction sigmoïde sont comprises dans l'intervalle $[0, 1]$, ce qui permet d'interpréter la sortie du neurone comme une probabilité [8].

I.5. Les réseaux de neurones

Un réseau de neurones est défini comme un ensemble de neurones formels, relié entre eux par des connexions qui représentent les poids. On désigne deux types de neurone dans un réseau :

- Les neurones de la couche cachée dont l'état interne est inconnu, leur sortie est connectée à d'autres neurones cachés ou aux neurones de sortie [8].
- Les neurones de sortie dont la valeur de sortie est connue.

I.6. Modèles de réseaux de neurones

Selon la typologie de connexion des neurones, ils sont classés en deux grandes catégories : réseaux non bouclés (non récurrents), et réseaux bouclés (récurrents) [9].

I.6.1. Réseaux de neurones non bouclé

Un réseau de neurone non bouclé est représenté graphiquement par un ensemble de neurones connectés entre eux. L'information circule des entrées vers les sorties son retour en arrière, on y trouve: le perceptron, réseaux multicouches [10].

I.6.1.1. Perceptron

C'est un des premiers réseaux de neurones conçu en 1958 par Rosenblatt, il est linéaire et monocouche (voir figure I.7). La première couche représente la rétine, les neurones de la couche suivante sont les cellules d'associations et la couche finale représente les cellules de décision, les sorties de neurones ne peuvent prendre que 2 états (-1 et 1 ou 0 et 1)[11]. Seuls les poids des liaisons entre la couche d'association et la couche finale peuvent être modifiés. La règle de modification des poids utilisée est la règle de Widrow-Hoff : si la sortie du réseau est égale à la sortie désirée, le poids de la connexion entre ce neurone et le neurone d'association qui lui est connecté n'est pas modifié. Dans le cas contraire, le poids est modifié par rapport à la différence entre la sortie obtenue et la sortie désirée.




Figure I.7 : Schéma de Perceptron

Chaque neurone de la couche de sortie effectue une somme pondérée de ces entrées, qui est donnée par l'équation suivante :

$$A_i = \sum_{i=1}^n x_i \cdot w_i + \theta \quad (\text{I.7})$$

La fonction d'activation des unités de cette fonction est de type fonction à seuil :

$$f(x) = \begin{cases} -1 & \text{si } x < 0 \\ +1 & \text{si } x \geq 0 \end{cases} \quad (\text{I.8})$$

$$\text{Par conséquent : } O = \begin{cases} 1 & \text{si } A_i < 0 \\ 0 & \text{si } A_i \geq 0 \end{cases} \quad (\text{I.9})$$

I.6.1.2. Réseaux multicouches

Apparus en 1985, les réseaux multicouches sont aujourd'hui les modèles les plus employés. Ils sont une amélioration de perceptron comprenant une ou plusieurs couches intermédiaire dites couches cachées, qui n'ont pas de contact direct avec l'extérieur, chaque neurone est relié aux neurones des couches précédentes et suivantes (voir figure I.8) [11].

Pour l'apprentissage, les perceptrons multicouches utilisent pour modifier leur poids un algorithme de rétro-propagation qui est une généralisation de La règle de Widrow-Hoff, il s'agit toujours de minimiser l'erreur quadratique en propageant la modification des poids de la couche de sortie jusqu'à la couche d'entrée.




Figure I.8 : Réseau multicouches

I.6.2. Réseaux de neurones bouclés

Par opposition aux réseaux non bouclés, les réseaux de neurones bouclés peuvent avoir une topologie de connexion quelconque, comprenant notamment des boucles qui ramènent aux entrées la valeur d'une ou plusieurs sorties. Les réseaux de neurones bouclés sont utilisés pour effectuer des tâches de modélisation de la dynamique de système, de commande de processus, ou de filtrage [10]. On y trouve : réseau ART.

I.6.2.1 Réseau ART (Adaptive Resonance Theory)

Le réseau ART est formé d'une couche d'entrée qui est aussi la couche de sortie et d'une couche cachée, comme indiqué sur la figure I.9. Tous les neurones de la couche d'entrée sont reliés aux neurones de la couche cachée, et tous les neurones de la couche cachée sont reliés à chacun des neurones de la couche de sortie [12].




Figure I.9 : Réseau ART

I.7.Apprentissage des réseaux de neurones

Une caractéristique des réseaux de neurones est leur capacité à apprendre (à reconnaître une lettre, une image,...), mais cette connaissance n'est pas acquise dès le départ. La plupart des réseaux de neurones apprennent via des exemples, selon un algorithme d'apprentissage, qui est la propriété la plus intéressante des réseaux de neurones. Il existe trois types d'apprentissage : le supervisé, le non supervisé et celui par renforcement.

I.7.1.Apprentissage supervisé

Dans le cas supervisé, le réseau est forcé à converger vers un état final précis, ce qui nécessite une connaissance à priori de la sortie désirée. L'apprentissage supervisé consiste à calculer la sortie du réseau, ajuster les poids de façon à réduire l'écart entre la sortie mesurée et la sortie désirée. Les règles d'apprentissage les plus connues sont : la règle de Widrow-Hoff et la règle de rétro-propagation de gradient [10].

I.7.2.Apprentissage non supervisé

Comme son nom l'indique, il est l'opposé du premier. Dans ce type d'apprentissage, on ne fournit pas au réseau les sorties que l'on désire obtenir, on le laisse évoluer librement jusqu'à ce qu'il se stabilise, à l'aide des règles qui modifient les paramètres du réseau et en fonction des exemples fournis en entrée. Parmi ces règles, nous citons la règle d'Hebb.

I.7.3.Apprentissage par renforcement

Dans ce cas, bien que les sorties désirées ne soient pas connues directement, il y a un moyen quelconque de connaître si les sorties des réseaux de neurones artificiels s'approchent ou s'éloignent du but visé. Ainsi, les poids sont ajustés de façon plus ou moins aléatoire et la modification est conservée si l'impact est positif ou rejeté sinon [13].

I.8.Règles d'apprentissage

I.8.1.Règle de Hebb

La loi de Hebb s'applique aux connexions entre neurones, comme représenté sur la figure I.10 suivante [14] :




Figure I.10 : connexions entre neurones

Cette règle peut être traduite par l'équation suivante :

$$W_{ij}(t + 1) = W_{ij}(t) + \eta S_i S_j \quad (\text{I.10})$$

Avec :

$W_{ij}(t)$: poids de connexion entre le neurone i et le neurone j à l' instant t .

η : constante positive représentant le pas d'apprentissage.

S_i : sortie du neurone i .

S_j : sortie du neurone j .

I.8.2.Règle de Widrow-Hoff

ΔW_{ij} : est le changement a effectué pour la valeur w_{ij} .

X_i : valeur de sortie (0 ou 1) de la $i^{\text{ème}}$ cellule d'entrée.

Y_d : réponse théorique (ou désirée).

Y_j : réponse de la $j^{\text{ème}}$ cellule de sortie (0 ou 1).

$w_{ij}(t)$: le poids de connexion au temps t .

η : constante positive généralement comprise entre 0 et 1.

I.8.3.Règle de Rosenblatt

Son principe est d'adapter les poids suivant ces formules :

$$W_{ij}(t + 1) = w_{ij}(t) + \Delta W_{ij} \quad (\text{I.11})$$

$$\Delta W_{ij} = \eta(Y_d - Y_j) \quad (\text{I.12})$$

I.8.4. Règle de rétro-propagation

Appliquée aux réseaux multicouches (voir figure I.11). Parmi les différentes techniques possibles, celle de la rétro-propagation de gradient (*Back Propagation*) est la plus utilisée. Elle permet de calculer le gradient de l'erreur pour chaque neurone, puis corriger les poids de connexion en fonction du gradient obtenu de la dernière couche vers la première. On l'appelle souvent la technique de rétro-propagation du gradient l'algorithme classique de correction des erreurs basé sur le calcul du gradient [15].

Avant de passé au fonctionnement de l'algorithme de la rétro-propagation, on doit d'abord calculer les sorties du réseau en propageant les valeurs de vecteurs d'entrées de couche en couche jusqu'à la couche de sortie.




Figure I.11 : exemple de réseau multicouche

Avec :

$X_i = [X_1, \dots, X_{n0}]$ Représente le vecteur d'entrée.

$Y_k = [Y_1, \dots, Y_{n2}]$ Représente le vecteur de sortie.

K_k^d représente la sortie désiré.

W_{ij} : poids de connexion entre la $i^{\text{ème}}$ entrée et la $j^{\text{ème}}$ unité cachée.

W_{kj} : poids de connexion entre la $j^{\text{ème}}$ unité cachée et la $k^{\text{ème}}$ unité de sortie.

L'entrée de la couche cachée est calculée comme suit :

$$a_j = \sum_{i=1}^{n0} W_{ij} X_i \quad (\text{I.13})$$

et la sortie des neurones de couche cachée est donnée par la relation suivante :

$$X_j = f(a_j) \quad (\text{I.14})$$

L'entrée de couche de sortie :

$$a_k = \sum_{j=1}^{n1} W_{kj} X_j \quad (\text{I.15})$$

et la sortie des unités de couche de sortie est calculée par la relation suivante :

$$Y_k = g(a_k) \quad (\text{I.16})$$

Fonctionnement de l'algorithme de la rétro-propagation

L'algorithme de rétro-propagation consiste à déterminer l'erreur entre la sortie désirée et la sortie de système :

$$E_k = Y_k^d - Y_k \quad (\text{I.17})$$

Soit la somme des erreurs quadratiques observées sur l'ensemble des neurones de la couche de sortie :

$$j = \frac{1}{2} \sum_{k=1}^{n^2} (E_k)^2 \quad (\text{I.18})$$

L'adaptation des poids du réseau commence par les poids des neurones de sortie puis passe à ceux des neurones d'entrée. La méthode d'adaptation des poids pour les neurones de la couche de sortie et ceux des neurones des couches cachées n'est pas la même.

Adaptation des poids d sortie

Pour modifier les poids W_{kj} , on doit minimiser le gradient de l'erreur $\frac{\partial J}{\partial W_{kj}}$ tel que la variation des poids est :

$$\Delta W_{kj} = -\eta \frac{\partial J}{\partial W_{kj}} \quad (\text{I.19})$$

Avec η est le taux d'apprentissage qui varie entre 0 et 1. On a :

$$\frac{\partial J}{\partial W_{kj}} = \frac{\partial J}{\partial Y_k} \cdot \frac{\partial Y_k}{\partial a_k} \cdot \frac{\partial a_k}{\partial W_{kj}} \quad (\text{I.20})$$

On dérivant chaque terme de (I.20), nous obtenons :

$$\frac{\partial J}{\partial Y_k} = -(Y_k^d - Y_k) \quad , \quad \frac{\partial Y_k}{\partial a_k} = g'(a_k) \quad , \quad \frac{\partial a_k}{\partial W_{kj}} = X_j$$

Nous remplaçons les résultats des dérivées dans l'équation précédente (I.20), nous trouvons :

$$\frac{\partial J}{\partial W_{kj}} = -(Y_k^d - Y_k) \cdot g(a_k) \cdot X_j \quad (\text{I.21})$$

$$\text{Nous avons : } \frac{\partial J}{\partial a_k} = \frac{\partial J}{\partial Y_k} \cdot \frac{\partial Y_k}{\partial a_k} = -(Y_k^d - Y_k) \cdot g(a_k)$$

On pose $\partial k = (Y_k^d - Y_k) \cdot g'(a_k)$ alors :

$$\frac{\partial J}{\partial W_{kj}} = -\partial k \cdot X_j \quad (\text{I.22})$$

Donc nous obtenons:

$$\Delta W_{kj} = -\eta \frac{\partial J}{\partial W_{kj}} = \eta \partial k \cdot X_j \quad (\text{I.23})$$

La nouvelle valeur, des poids de la couche de sortie, est donnée par la relation suivante :

$$W_{kj} = W_{kj}(n-1) + \Delta W_{kj}(n) \quad (\text{I.24})$$

De la même manière, Les poids de la couche cachée peuvent être réajustés par la formule suivante :

$$W_{ij} = W_{ij}(n - 1) + \Delta W_{ij}(n) \quad (I.25)$$

Avec $\Delta W_{ij} = -\eta \partial_j \cdot X_i$ et $-\partial_j = \left(-\sum_{k=1}^{n_0} \partial_k \cdot W_{kj} \right) \cdot f'(a_j)$

I.9.Mise en œuvre des réseaux de neurones

Les réseaux de neurones réalisent des fonctions non linéaires paramétrées. Leurs mises en œuvre nécessitent avant tout : la détermination des entrées et des sorties pertinentes, la collecte des données nécessaires à l'apprentissage et à l'évaluation des performances du réseau de neurones, vient ensuite le problème que redoute tous les utilisateurs, à savoir la détermination du nombre de couches cachées et le nombre de neurones dans chacune d'entre elles, en suite vient l'entraînement du réseau.

D'après Wierenga et Kluytmans le nombre des neurones doit être égal à celui de la couche d'entrée et d'après Venugopal et Baets, il faut qu'il soit égal à 75% de celui de la couche d'entrée et d'après Shepard, ce nombre est égal à la racine carrée du produit de nombre de neurones dans la couche d'entrée et celle de sortie. Mais en réalité, les analystes ne sont nullement convaincus, et estiment qu'il est préférable d'essayer le plus de taille possible, c.à.d. changer la taille régulièrement jusqu'à l'obtention de la meilleure performance [16] [17]. Par la suite, choisir la fonction d'activation des neurones contenus dans le réseau et la règle d'apprentissage qui s'adapte le mieux au système étudié.

I.10.Propriétés et limites des réseaux de neurones

I.10.1.Propriétés des réseaux de neurones

Les réseaux de neurones sont caractérisés par les propriétés suivantes:

- **la capacité d'adaptation** : elle se manifeste dans la capacité d'un réseau de neurones à s'adapter aux nouvelles contraintes et aux nouvelles données du monde extérieur.
- **Bonne résolution** : ils donnent de bons résultats même dans des domaines complexes.
- **Souplesse** : les réseaux de neurones sont capables de traiter une gamme très étendue de problèmes.
- **La généralisation** : elle se traduit par la capacité d'un système à apprendre, à partir d'un certain nombre d'exemples des comportements qui permettent de résoudre un problème donné.
- **Parallélisme** : les réseaux de neurones, par essence des « machines parallèles », peuvent donc bénéficier directement des architectures multiprocessus (tous les neurones d'une même couche sont indépendants).

I.10.2. Limites des réseaux de neurones

Les limites des réseaux de neurones résident dans :

- **Choix des attributs** : ce problème n'est évidemment pas spécifique aux réseaux de neurones, mais il est clair qu'il faut choisir soigneusement la représentation des données. Les attributs ne peuvent être plus qu'être numériques.
- **Processus d'apprentissage** :
 - Il peut être extrêmement long.
 - L'apprentissage par rétro-propagation des erreurs peut converger vers une solution sous-optimale.
 - Paralysie du réseau : les poids synaptique deviennent si grands que leur modification est inopérante sur le comportement des neurones.
 - Sur-spécification : lorsque l'apprentissage est trop prolongé, le réseau de neurone perd son pouvoir de généralisation. Il reconnaît les données de l'échantillon d'apprentissage, mais plus de nouvelles données similaires.
- **Architecture de réseau** : le nombre de neurones dans les couches d'entrée et de sortie sont généralement fixés par l'application, mais comment optimiser le nombre de couches cachées et le nombre de neurones dans ces couches ?
- **Interprétation** : il est quasi-impossible d'expliquer de manière compréhensible les résultats fournis par un réseau de neurones. Un réseau de neurone peut découvrir empiriquement des lois et les exploiter dans la résolution des problèmes, mais il ne peut pas formuler ces lois [18].

I.11. Domaines d'application des réseaux de neurones

Parmi les domaines d'application des réseaux des neurones, nous citons :

- **Approximation des fonctions** : les fonctions trop compliquées peuvent être approximées, grâce au réseau, par une somme de fonctions plus simples comme des polynômes ou des sigmoïdes.
- **Optimisation de trajectoires** : on peut, par exemple, déterminer quelle est la meilleure trajectoire pour un avion, une fusée...
- **Reconnaissance** : un réseau peut servir à reconnaître des caractères. Cela est déjà utilisé à la poste pour lire les codes postaux, ou même dans certaines banques pour lire

les chèques. Il est aussi possible de retrouver la prononciation des mots à partir d'un texte.

- **Prévision** : on utilise de plus en plus les réseaux pour faire des prévisions en marketing (prédiction de comportement, de possibilité de vente d'un produit, ...) ou pour le trafic routier,..., mais les prévisions en météo ou en bourse sont trop compliquées à réaliser.
- **Contrôle** : on peut contrôler les produits dans une industrie.
- **Robotique** : certains robots sont dotés de réseau de neurones. Des entreprises japonaises se vantent déjà de leur utilisation, même pour des produits électroménagers ou informatiques [13].
- **La classification**: une autre grande catégorie de problème consiste à attribuer de façon automatique un objet à une classe, parmi d'autres classes possibles. Et en raison de leur propriété d'approximation, les réseaux de neurones sont capables d'estimer de manière précise la probabilité d'appartenance d'une classe parmi plusieurs possibles [9].

I.12.Conclusion

Ce chapitre introduit les notions de base sur les réseaux de neurones artificiels, la représentation de modèle biologique et mathématique du neurone, les différentes architectures. Une propriété intéressante des réseaux de neurones est leur capacité d'apprentissage. L'intérêt d'utiliser les réseaux de neurones artificiels dans notre travail est leur capacité à s'adapter aux différents problèmes, comme dans le domaine de la classification. Les réseaux de neurones donnent de bons résultats, mais il existe des problèmes qui ne peuvent pas être résolus par les règles d'apprentissage classiques, le manque d'une méthode d'apprentissage rapide ne peut pas répondre, souvent, à la demande réelle. Pour résoudre ce problème un nouvel algorithme appelé ELM (*Extreme Learning machine*) a été proposé par Huang [25], que nous détaillerons dans le prochain chapitre.

II.1.Introduction

Apprentissage machine extrême (*ELM : Extreme Learning Machine*) est un algorithme d'apprentissage pour les réseaux de neurones *feedforward* à une seule couche cachée. Dans les réseaux ELM, les poids d'entrée et les biais de couche cachée sont générés de manière aléatoire et restent constants, et les poids de sortie sont calculés d'une manière analytique par la méthode des moindres carrés. Par conséquent, la phase d'apprentissage nécessite un temps de calcul très court, en plus de la bonne capacité de généralisation de ce réseau. L'ELM est devenu un sujet de recherche important pour la reconnaissance de formes et l'apprentissage machine. L'ELM et ces variantes présentent une précision concurrentielle avec une efficacité exceptionnelle dans de nombreuses applications, en particulier, la classification de données. Cependant le réseau de neurones ELM n'est pas adapté à la classification des images brutes, sans la phase d'extraction de caractéristiques, même en utilisant un très grand nombre de neurones dans la couche cachée.

Pour remédier à ce problème, Huang a combiné le concept de champs récepteurs locaux (*LRF : Local Receptive Field*), inspiré des réseaux de neurones à convolution, avec le principe de fonctionnement d'ELM, et il a proposé l'ELM-LRF (*Extreme Learning Machine-Local Receptive Field*). La couche d'entrée et la couche cachée dans l'ELM-LRF sont localement connectées, ce qui permet au réseau de considérer les structures locales de l'image.

Dans ce chapitre, nous allons décrire le réseau ELM-LRF. Nous commençons, d'abord, par une brève introduction sur quelques notions de la classification de données, et les réseaux de neurones classiques en classification d'images.

II .2.Classification de données

Pour décider à quel groupe, parmi plusieurs possibles, un objet appartient est un problème difficile dans la plus part des cas. La classification consiste à affecter les objets d'un ensemble de données à des catégories ou des classes prédéfinies, et l'algorithme qui réalise une classification est appelé classifieur.

On parle de la classification des données de très grandes dimensions, lorsque les exemples correspondants à des images, ou chaque image peut être caractérisée par un

ensemble d'attributs tels que les attributs de couleur, de texture, ou de forme. La classification des images intervient comme étape très importante dans différentes applications comme la reconnaissance des formes telle que la reconnaissance des visages, des empreintes, etc.

Plusieurs méthodes de classification ont été proposées, en général, ces dernières s'exécutent en deux étapes : l'étape d'apprentissage celle de test qui permet d'évaluer les performances d'un classifieur. L'étape la plus importante, s'agit de la phase d'apprentissage, consiste à élaborer des règles de classification à partir des connaissances disponibles. L'apprentissage peut être soit non supervisé soit supervisé.

Les algorithmes d'apprentissage non supervisé consistent à regrouper des objets, appartenant à un ensemble T, en classes restreintes de telle sorte que les objets d'une même classe soient les moins dispersés possibles. Par contre, les algorithmes d'apprentissage supervisé utilisent un ensemble d'exemples, ou les classes d'appartenance sont connues au préalable, et à partir de cet ensemble des règles d'affectation seront définies. Les différentes méthodes de classification utilisant ces types d'apprentissage sont représentées sur le schéma suivant :




Figure II.1: Les différentes méthodes de classification

La plupart des méthodes de classification mentionnées ont été largement appliquées dans plusieurs domaines y compris celui de la classification des images. Ces dernières passent toujours par l'étape d'extraction de caractéristiques, qui n'est pas comprise dans le réseau, et l'utilisation de l'image brute, au niveau pixel, est difficile vu impossible.

Dans notre travail, nous nous sommes intéressés aux méthodes d'affectation qui sont basées sur la notion d'apprentissage supervisé. Les réseaux de neurones sont très utilisés pour la classification, en particulier, les réseaux de neurones perceptron multicouches de type *feedforward*. Dans cette catégorie s'inscrit les réseaux de neurones à convolution et le réseau ELM-LRF, qui permettent l'exploitation brute de l'image, sans aucune étape de prétraitement au préalable. Ils ont montrés, dans la littérature, de meilleurs résultats de classification ainsi une bonne capacité de généralisation.

II.3.Machine d'apprentissage extrême à champs récepteurs locaux (ELM-LRF)

Le réseau de neurones ELM à champs récepteurs locaux a été mis en œuvre par Huang et al. [19] en 2015. Huang a combiné le concept de champs récepteurs locaux (*LRF : Local Receptif Field*), inspiré des réseaux de neurones à convolution, avec le principe de fonctionnement d'ELM, et il a proposé le réseau ELM-LRF. En effet, Le réseau *ELM-LRF* est une architecture générique du réseau ELM [20], qui a été élaboré pour résoudre les problèmes de traitement d'images et des problèmes similaires dans lesquels une densité de connexion peut être demandée, c'est-à-dire que les connexions entre les neurones de la couche d'entrées et ceux de la couche cachée sont délimitées par des champs récepteurs locaux. Des neurones combinatoires sont également utilisés dans le réseau, pour fournir une invariance à la translation, en combinant plusieurs neurones cachés ensemble. Avant de décrire le réseau ELM-LRF et d'expliquer son fonctionnement, il est primordial, de donner une petite introduction sur les réseaux de neurones à convolution.

II.3.1.Les réseaux de neurones à convolution

Les réseaux de neurones à convolution ou conventionnels (*CNN* pour *Convolutional Neural Network*), sont des réseaux de neurones artificiels *feedforward*, dans lesquels la connexion entre les neurones est inspirée du cortex visuel. Ce type de réseaux exploite les images brutes en entrée et l'étape d'extraction de caractéristiques est comprise dans le réseau lui-même.

II.3.1.1. Architecture des réseaux de neurones convolutifs (CNN)

Les réseaux de neurones à convolution sont, à ce jour, les modèles les plus performants pour la classification des images [21], ils comportent deux parties bien distinctes (voir figure II.2). La première partie, composée de couches de neurones localement liés, est une succession alternant entre couches de convolution et couches de sous-échantillonnage (*pooling*). Elle est considérée comme une partie d'extraction automatique de caractéristiques, le CNN est qualifié d'extracteur de caractéristiques le plus performant dans la littérature. Tandis que la deuxième partie, composée de couches de neurones complètement connectées, est utilisée pour la classification. Le rôle de cette partie est de combiner les caractéristiques, issues à la sortie de la première partie, pour prendre la décision sur l'appartenance d'une image à telle ou telle classe [22].




Figure II.2: Architecture des réseaux de neurones a convolution

II.3.2. Réseau de neurones à apprentissage machine extrême (ELM)

ELM est un algorithme d'apprentissage des réseaux de neurones à une seule couche cachée de type *feedforward* (voir la figure II.3), il est différent des algorithmes d'apprentissages neuronaux classiques. Dans le réseau ELM, le nombre de neurones de la couche cachée, est défini de façon adaptative, et les poids des neurones de la couche cachée sont assignés de façon aléatoire et restent constants. Cependant les poids des neurones de la couche de sortie, contrairement aux réseaux de neurones classiques, sont obtenus par la méthode des moindres carrés. Par conséquent, l'ELM génère une solution optimale unique. Le réseau ELM est un réseau de neurones d'architecture très simple et le seul paramètre à

fixer est le nombre de neurones dans la couche cachée, en plus il est efficace pour la classification de données [20][23][24].




Figure II.3: Architecture d'ELM

Avec :

$\tilde{N}$: le nombre de neurones de la couche cachée.

X_N : les données d'entrée.

$W_{\tilde{N}}$: les poids reliant le $L^{\text{ième}}$ neurone caché et les neurones d'entrée.

$\beta_{\tilde{N}}$: les poids reliant le $L^{\text{ième}}$ neurone cachée et les neurones de sortie.

$b_{\tilde{N}}$: le biais du $L^{\text{ième}}$ neurone cachée.

$w_{\tilde{N}} \cdot X_N$: désigne le produit scalaire entre $W_{\tilde{N}}$ et X_N .

g : est la fonction d'activation.

t_m : Les sorties de réseau.

Le réseau ELM est modélisé par le système d'équations suivant :

$$\sum_{i=1}^{\tilde{N}} \beta_i g(W_i \cdot X_j + b_i) = t_i, \quad j = 1, \dots, N. \quad (\text{II.1})$$

II.3.2.1.Algorithme ELM

Pour N exemples d'apprentissage (X_i, t_i) tel que : $X_i = [x_{i1}, x_{i2}, \dots, x_{in}]^T \in R^n$, n est la dimension de ces exemples (le nombre d'entrées du réseau) et $t_i = [t_{i1}, t_{i2}, \dots, t_{im}]^T \in R^m$ avec m est le nombre de sorties du réseau, dans le cas de la classification, il correspond au nombre de classes), $\tilde{N}$ est le nombre de neurones dans la couche cachée. L'algorithme d'apprentissage du réseau ELM proposé par **Guang-Bin Huang** [25], peut être résumé en ces étapes suivantes :

Étape 1: affecter de manière aléatoire les poids d'entrée W_i et les valeurs du biais b_i tel que :

$W_i = [w_{i1}, w_{i2}, \dots, w_{in}]^T$ est le vecteur des poids reliant le $i^{\text{ième}}$ neurone caché avec les neurones d'entrée, $i = 1, \dots, \tilde{N}$.

b_i est le biais de chaque neurone caché.

Étape 2: calculer la matrice de sortie de la couche cachée H tel que :

$$H(W_1 \dots W_{\tilde{N}}, b_1 \dots b_{\tilde{N}}, X_1 \dots X_N) = \begin{bmatrix} g(W_1 \cdot x_1 + b_1) & \dots & g(W_{\tilde{N}} \cdot x_1 + b_{\tilde{N}}) \\ \vdots & & \vdots \\ g(W_1 \cdot x_N + b_1) & \dots & g(W_{\tilde{N}} \cdot x_N + b_{\tilde{N}}) \end{bmatrix} \quad (II.2)$$

La matrice H est de dimension $N \times \tilde{N}$.

Étape 3: calculer le poids de sortie β , tel que :

$$\beta = H^+ T$$

Avec $T = [t_1, \dots, t_N]^T$ est la matrice de sortie du réseau de dimension $N \times m$. H^+ est la pseudo inverse de Moore-Penrose de la matrice H , en utilisant la décomposition en valeurs singulières (SVD, Singular Value Decomposition) [26] [27].

II.3.2.2.Caractéristiques d'ELM

Depuis l'apparition de réseau ELM en 2006, il a été exploité dans plusieurs applications, telle que la reconnaissance de forme, la reconnaissance d'action humaine, la classification des images, en raison de ces différentes caractéristiques que nous citons ci-dessous [25][28] :

- L'algorithme d'apprentissage ELM est beaucoup plus simple que la plupart des algorithmes d'apprentissage des réseaux de neurones feedforward.

- De nombreuses fonctions d'activation non linéaire peuvent être utilisées dans l'ELM, particulièrement, la fonction sigmoïde.
- Les poids d'entrée et les biais de la couche cachée, des réseaux de neurones perceptrons multicouches de type *feedforward*, peuvent être affectés aléatoirement si la fonction d'activation est infiniment différentiable.
- Un réseau de neurones perceptrons multicouches de type *feedforward*, peut être simplement considéré comme un système linéaire et les poids de sortie peuvent être déterminés analytiquement par une simple opération d'inverse généralisé de matrice de sortie de couche cachée.
- Le réseau ELM tend à avoir la plus petite norme de l'erreur quadratique, pour une meilleure performance de généralisation.
- La vitesse d'apprentissage de l'ELM peut être des milliers de fois plus rapide que les algorithmes classiques, comme la rétropropagation du gradient.
- ELM peut résoudre tous les problèmes de régression avec la précision souhaitée et adopté aux problèmes de classification.
- Les algorithmes classiques d'apprentissage basés sur le gradient peuvent faire face à plusieurs problèmes comme les minimums locaux, l'ELM tend à atteindre les solutions sans ces questions triviales.
- Il n'y a pas de paramètre à fixer sauf le nombre de neurones cachés.
- Le temps d'apprentissage de ELM est consacré au calcul de la pseudo inverse de Moore-Penrose de la matrice de sortie de couche cachée H .
- Une des caractéristiques les plus marquées d'ELM est que les poids de la couche cachée n'ont pas besoin d'être ajustés.
- La performance de généralisation de ELM est très stable sur un large nombre de neurones cachée, bien que les performances de généralisation tendant à s'aggraver lorsque trop peu ou trop de neurones cachée.

II.4. Architecture d'ELM-LRF

Comme son nom indique, l'ELM-LRF introduit la notion du champ récepteur local dans la couche d'entrée obtenant ainsi un ELM localement connecté (voir figure II.4). La couche cachée de ELM-LRF se compose d'une couche de convolution et d'une couche de *pooling*. La couche de convolution est composée de plusieurs cartes de caractéristiques qui sont de nombre de neurones cachés. Les poids d'entrée entre la couche d'entrée et la couche

de convolution sont générés de manière aléatoire selon une distribution de probabilité continue. L'opération du *pooling* est utilisée pour formuler les neurones combinatoires dans la couche de *pooling* [22]. Cette dernière est en connexion complète avec la couche de sortie. Les poids de sortie sont calculés analytiquement comme dans ELM à l'aide de la solution des moindres carrés. Le réseau ELM-LRF est lié aux CNN, ils utilisent, tous les deux, directement des entrées brutes sans aucun prétraitement au préalable. En plus, ils appliquent des connexions locales pour forcer le réseau à apprendre les corrélations spatiales dans le cadre de données images. Dans la suite de ce chapitre, nous décrivons chacun des composants de ce réseau et son comportement.




Figure II.4: Architecture d'ELM-LRF

II.4.1. Les champs récepteurs locaux

Chaque neurone de la couche cachée est relié à une petite région de la couche d'entrée (voir figure II.4), d'où l'appellation champ récepteur local. Le champ récepteur de chaque neurone caché est composé d'un ensemble de neurones d'entrée à l'intérieur d'une fenêtre de taille prédéterminée, il est donc considéré comme un masque centré sur chaque pixel de l'image. Les champs récepteurs locaux sont balayés, par un pas d'un pixel horizontalement et

verticalement, sur toute l'image d'entrée. Cela mène directement à l'opération de convolution, très simple et facile, entre le masque de convolution et l'image en entrée qui permet d'extraire des caractéristiques de l'image. Les connections champs récepteurs locaux sont des connections aléatoires, qui sont denses autour de quelques neurones d'entrée et négligées plus loin. Par conséquent, l'ELM-LRF apprend les structures locales et génère des représentations plus significatives au niveau de la couche cachée. Les coefficients des masques de convolution sont générés de manière aléatoire en utilisant une distribution de probabilité continue. Le résultat du produit de convolution, entre l'image et le champ récepteur, génère une carte de caractéristiques notée C . La taille de cette carte est de $(Nl - r + 1) \times (Nc - r + 1)$ avec $r \times r$ est la taille des champs récepteurs et l'image en entrée est de taille $Nl \times Nc$ (Nl nombre de lignes et Nc nombre de colonnes).

II.4.2. La structure de pooling

La structure de *pooling* introduit de l'invariance aux faibles rotations et translations pouvant apparaître en entrée. Elle est utilisée pour formuler la combinaison des neurones. Comme dans la structure de champs récepteurs, la carte de *pooling* est obtenue par balayage du masque de *pooling*. Le masque de *pooling* est de taille $(2e + 1) \times (2e + 1)$ (voir figure II.4), sur toute la carte de caractéristiques. La carte de *pooling* est de même taille que celle de caractéristiques. En revanche, dans les réseaux de neurones à convolution, permet de réduire le nombre de caractéristiques extraites après convolution. En effet, la carte du *pooling* est de taille réduite par rapport à la carte de caractéristiques.

Soient $c_{i,j,k}$ et $h_{p,q,k}$, la valeur du coefficient (i,j) dans la $k^{\text{ième}}$ carte de caractéristiques et la valeur du coefficient (p,q) dans la carte de *pooling*, respectivement. Les coefficients de la carte de *pooling* sont calculés en utilisant la relation ci-dessous :

$$h_{p,q,k} = \sqrt{\sum_{i=p-e}^{p+e} \sum_{j=q-e}^{q+e} c_{i,j,k}^2} \quad (\text{II.3})$$

Avec $p = 1, \dots, (Nl - r + 1)$ et $q = 1, \dots, (Nc - r + 1)$

Les opérations du *pooling* introduisent la non-linéarité, ce qui est très important pour les opérations du traitement des images réussies.

II.4.3. Poids de sortie β

La couche *pooling* est en connexion complète avec la couche de sortie comme montré sur la figure (II.4). Les poids de sortie β sont calculés analytiquement comme dans la troisième étape de l'algorithme ELM :

$$\beta = H^+ T \quad (II.4)$$

Avec : H^+ est l'inverse généralisé de Moore-Penrose de la matrice H [31].

La matrice H le résultat d'application d'une étape de convolution suivie de celle de *pooling*, elle est construite comme suit :

- Pour une image en entrée, concaténer les valeurs de chaque carte de *pooling* résultante en un vecteur de taille $(Nl - r + 1) \times (Nc - r + 1)$. Ensuite, concaténer les k vecteurs résultants, correspondants à k cartes de *pooling*, en un vecteur de taille $k \times (Nl - r + 1) \times (Nc - r + 1)$. Ce vecteur de caractéristiques regroupe l'ensemble de caractéristiques extraites, par les deux opérations convolution et *pooling*, de l'image introduite à l'entrée du réseau.
- Pour N images en entrée, concaténer verticalement les vecteurs correspondants à chacune des N images, nous obtenons, la matrice de sortie de la couche cachée H de dimension $N \times (k \times (Nl - r + 1) \times (Nc - r + 1))$.

II.5 Algorithme ELM-LRF

Le processus de modélisation du réseau de neurones ELM-LRF peut être résumé en cet algorithme qui composé des étapes suivante :

- Choisir le nombre de cartes ce qui correspond au nombre de champs récepteurs locaux, et correspond aussi au nombre de neurones dans la couche cachée.
- Fixer la taille des masques de convolution et de *pooling*.
- Initialiser de manière aléatoire, les coefficients des masques de convolution.
- Extraire les caractéristiques des images de l'ensemble d'apprentissage, cette étape est effectuée en trois sous étapes :
 - Calculer les cartes de convolution ;
 - Calculer les cartes de *pooling*;

- Transformer les cartes de *pooling* de chaque image en vecteur et concaténer les vecteurs caractéristiques de toutes les images en la matrice H .
- Calculer les poids de sortie β du réseau ELM-LRF, tel que $\beta = H^+T$.

Une fois les poids de sortie β sont déterminés, pour toute image I_1 , dont nous cherchons la classe correspondante, il suffit de calculer le vecteur de sortie T_1 du réseau qui est donné par la relation suivante :

$$T_1 = H_1\beta \quad (\text{II.5})$$

Avec H_1 est le vecteur caractéristiques, à la sortie de la couche cachée, de l'image I_1 .

II.6 Différence entre l'ELM-LRF et les réseaux de neurones à convolution

- **Champ réceptif local :** L'ELM-LRF offre plus de flexibilité au niveau de champs récepteurs locaux. Bien que les réseaux de neurones à convolution utilisent les champs récepteurs locaux conventionnels, l'ELM-LRF choisi les neurones conventionnels aléatoires comme champs récepteurs locaux spécifiques.
- **Apprentissage :** tous les poids des réseaux de neurones à convolution doivent être ajustés durant la phase d'apprentissage. L'algorithme d'apprentissage, le plus utilisé, est celui de la rétro-propagation, par conséquent, le CNN fait face aux problèmes liés à cet algorithme. En revanche l'ELM-LRF génère de manière aléatoire les poids qui relient les neurones de la couche d'entrée avec ceux des neurones de la couche cachée et restent constants, seuls les poids de sortie sont calculés analytiquement, en une seule itération, ce qui fait de l'ELM-LRF déterministe et efficace.
- **Nombre de couches dans l'étage d'extraction de caractéristiques :** dans l'ELM-LRF, l'étage d'extraction de caractéristiques comporte une seule couche de convolution suivie de celle de *pooling*. Par contre les CNNs, deux ou plus de succession de couche cachée et celle de *pooling* sont nécessaire. Par conséquent, l'architecture d'ELM-LRF est plus simple que celle des réseaux de neurones à convolution.

II.7 Conclusion

Dans ce chapitre, nous avons étudié le réseau ELM-LRF (architecture et fonctionnement), ce dernier est un réseau générique du réseau ELM, Le réseau ELM-LRF est

un réseau constitué d'un étage d'extraction de caractéristiques suivi d'étage de classification. Contrairement au réseau ELM-LRF, l'étape d'extraction de caractéristiques est effectuée en dehors des réseaux de neurones classiques, ces derniers ne se préoccupent que de la classification, à l'exception des réseaux de neurones à convolution et les réseaux profonds [23]. ELM-LRF proposé est caractérisé par le temps de calcul qui est extrêmement rapide, la meilleure précision par rapport aux autres algorithmes qui nécessite beaucoup de calcul. Les cartes de caractéristique représentent différentes abstraction de l'image, rendent le classement ultérieur facile et précis. Dans le chapitre suivant, Nous allons tester le réseau ELM-LRF, sur deux bases d'images de taille et de caractéristiques différentes, dans le but de classification des images.

III.1.Introduction

Après avoir étudié le réseau ELM-LRF, nous allons le tester pour la classification des images de types différents à savoir : niveau de gris et en couleur. A cet effet, nous avons opté pour deux bases d'images : la base de visage Yalefaces [32] et la base ALOI [33]. Toutes les images des deux bases sont étiquetées, ce qui permet de d'évaluer les résultats de la classification par rapport à la vérité terrain. Au début de ce chapitre, nous présentons les deux bases, nous décrivons leurs contenus et leurs caractéristiques. Ensuite, nous présentons, les différents tests que nous avons réalisé, et chacun correspondant à un paramétrage donné du réseau ELM-LRF.

III.2.Présentation des bases d'images

Pour évaluer les résultats d'application du réseau ELM-LRF en classification des images, nous avons utilisé deux bases d'images : la base Yalefaces et la base AloI.

III.2.1.Base de données Yalefaces

Cette base contient 165 images, de taille 243x320 pixels en niveau de gris, de visage de 15 individus (15 classes). Chaque individu est représenté par 11 images faciales prises dans des conditions différentes. Cette base contient à la fois des images des individus pour différentes expression faciales (souriant, triste (mécontent), yeux fermés, surpris et clin d'œil), ainsi que pour différentes conditions d'acquisition (éclairage centré, éclairage à droite, éclairage à gauche, port de lunettes). Sur la figure III.1, nous présentons les 11 images d'un individu de la base, chaque image est accompagnée par la description qui la caractérise.



Figure III.1 : les 11 images correspondantes à un individu.

III.2.2 Base d'images ALOI

La base ALOI est une collection de 72000 images, en couleur de taille 192x144 pixels, qui ont été prises avec des variations systématiques de l'angle de vue et réparties en 1000 objets, quelques exemples d'objets sont données sur la figure III.2.



Figure III.2 : quelques exemples d'objets de la base ALOI.

Chaque objet est représenté par 72 images couleurs enregistrées en faisant tourner l'objet autour de son axe vertical avec une rotation de 5° . Sur la figure III.3, nous montrons les images correspondantes à un objet avec des angles de rotation de 45° .




Figure III.3 : les images d'un objet de la base ALOI avec des angles de rotation de 45° .

En plus, la base Aloï contient 10 objets qui sont très similaires, comme montré sur la figure III.4.



Figure III.4 : les objets de la base ALOI très similaires.

III.3. Tests et résultats

Nous présentons dans cette partie les résultats expérimentaux de la classification, obtenus à partir d'application d'ELM-LRF sur les deux bases d'images. Les tests ont été implémentés avec **MATLAB** version **7.10 (R2010a)** sous l'environnement Windows7, et exécuté sur un pc Acer Nplify 802.11b/g/n et capacité de 32 bit.

III.3.1. Tests

Avant d'effectuer nos tests, nous avons, en premier, répartis chaque base d'images en deux ensembles qui sont : l'ensemble d'apprentissage et celui de test. L'ensemble d'apprentissage est utilisé pour déterminer les paramètres du modèle de classification, c'est la détermination des poids de sortie β du réseau ELM-LRF. L'ensemble de test sert à évaluer les résultats de la classification du réseau, en calculent le taux de mauvaise classification. Ce taux est déterminé en divisant le nombre de cas mal classés sur le nombre des cas testés *100.

III.3.1.1. Préparation de données

La base Yalefaces : pour chaque individu, nous avons pris les 6 premières images pour l'apprentissage et les 5 restantes pour le test comme montré sur les figures III.5 et III.6. Donc, l'ensemble d'apprentissage regroupe 84 images (14 individus*6 images) et dans l'ensemble test, nous avons 70 images restantes (14 individus *5 images).



Figure.III.5 : les images sélectionnées pour l'apprentissage



Figure III.6 : les images sélectionnées pour le test

Base ALOI : Vue le problème d'espace mémoire, nous n'avons utilisé que 10 objets de la base ALOI. Nous les avons répartis de 4 façons différentes, pour entraîner et tester le réseau ELM-LRF, comme illustrer dans le tableau ci-dessous. Pour plus de clarté nous avons donné un exemple pour chaque partition (voir figure III.7. 8.9). La 4^{ème} partition concerne les 10 objets similaires.

Partition	Ensemble d'apprentissage		Ensemble test	
	Nbre d'images/individus	Vues correspondantes	Nbre d'images/individus	Vues correspondantes
1 ^{ère} partition	4	0° :90° :360°	4	45° :90° :360°
2 ^{ème} partition	8	0° :45° :360°	14	25° :25° :360°
3 ^{ème} partition	8	0° :45° :360°	8	25° :45° :360°
4 ^{ème} partition	18	0° :20° :360°	18	10° :20° :360°

Tableau III.1 : les différentes partitions de la base ALOI




Figure III.7 : Exemple des images d'un objet de la 1^{ère} partition : (a) apprentissage, (b) test




Figure III.8 : Exemple des images d'un objet de la 2^{ème} partition : (c) apprentissage, (d) test




Figure III.9 : Exemple des images d'un objet de la 3^{ème} partition : (e) apprentissage, (f) test

Dans les tests que nous avons effectués, nous avons étudiés l'influence de trois paramètres : le nombre de cartes (le nombre de neurones de la couche cachée), la taille du masque de convolution et celle de *pooling*. Nous avons varié les trois paramètres tels qu'à chaque fois nous varions le nombre de carte, nous fixons la taille du masque de convolution et celle du masque de *pooling*. Pour chaque test, nous prélevons le temps de test et nous calculons le taux de mauvaise classification (ou le taux d'erreur).

III.3.2. Résultats et interprétation

Les résultats de classification avec ELM-LRF pour les deux bases sont résumés dans les tableaux ci-dessous. Nous ne pouvons pas utiliser la taille réelle des l'image vu l'insuffisance de l'espace mémoire. Par conséquent, nous avons opté pour la réduction de la taille de l'image de 50%, 20% et de 10%.

III.3.2.1. Résultats de la classification de la base Yalefaces

Les résultats de classification de la base Yalefaces sont résumés dans les trois tableaux ci-dessous, avec les trois différentes résolutions des images.

La résolution de 0.5 (voir tableau III.2) : Le meilleur taux de bonne classification est de 97.15%, ce qui correspond à 2 images mal classés et un taux d'erreur de 2.85%. Ce résultat

est obtenu pour 16 cartes, avec masque de convolution de taille 5x5 et celui de *pooling* est de taille 3x3.

Nbre de carte	Taille de pooling	Nbre images mal classées avec masque conv 3x3	Taux erreur (%)	Temps test (s)	Nbre images mal classées avec masque conv 5x5	Taux erreur (%)	Temps test(s)
5	3x 3	4	5.71	2.60	4	5.71	2.25
	5x5	4	5.71	2.20	3	4.28	2.40
10	3x3	3	4.28	3.81	4	5.71	4.22
	5x5	3	4.28	4.10	3	4.28	4.01
15	3x3	3	4.28	5.97	3	4.28	6.06
	5x5	3	4.28	6.22	4	5.71	6.10
16	3x3	3	4.28	8.68	2	2.85	6.33
	5x5	3	4.28	6.84	4	5.71	6.63

Tableau III.2 : la classification avec une résolution 0.5 (image de 124x140 pixels) 243x320

La résolution 0.2 (voir tableau III.3), le meilleur taux de bonne classification est également de 97.15% pour cette résolution mais avec 20 cartes et avec taille du masque de convolution de 5x5 et de 3x3 pour le *pooling*. Ce taux correspond à 2 images mal classées et un taux d'erreur de 2.85%.

Nbre de carte	Taille du masque de pooling	Nbre images mal classées avec masque conv 3x3	Temps test(s)	Taux erreur (%)	Nbre images mal classées avec masque conv 5x5	Temps test(s)	Taux erreur (%)
5	3x 3	4	1.28	5.71	3	1.36	4.28
	5x5	6	1.26	8.57	6	1.23	8.57
10	3x3	3	1.62	4.28	4	1.89	5.71
	5x5	6	1.72	8.57	6	1.54	8.57
20	3x3	3	2.24	4.28	2	2.40	2.85
	5x5	5	2.30	7.14	5	2.20	7.14
40	3x3	4	5.26	5.71	5	4.11	7.14
	5x5	5	5.48	7.14	3	4.39	4.28
60	3x3	4	7.48	5.71	3	7.19	4.28
	5x5	9	6.96	11.85	5	6.87	7.14
80	3x3	4	11.68	5.75	5	11.64	7.14
	5x5	10	10.91	14.28	8	10.4	11.42
99	3x3	7	18.24	10	3	14.63	4.28
	5x5	10	18.04	14.28	4	15.92	5.71

Tableau III.3 : la classification avec une résolution 0.2 (image de 48x64 pixels)

La résolution 0.1 (voir tableau III.4), le taux de bonne classification est de 92.86% qui correspond à 5 images mal classées sur 154 images au total, avec 20 cartes de caractéristiques et un masque de convolution 5x5, et de *pooling* 3x3. le temps de test varie entre [0.93ms 7.88s], et le taux d'erreur varie entre [7.14 31.42], avec cette résolution on peut aller jusqu'à 200 carte de caractéristique, le problème d'espace mémoire surgit.

Nbre de cartes	Taille de pooling	Nbre images mal classées avec masque conv 3x3	Temps test(s)	Taux erreur (%)	Nbre images mal classées avec masque conv 5x5	Temps test(s)	Taux erreur (%)
5	3x3	6	1.33	8.57	12	1.16	10
	5x5	9	1.16	12.85	9	1.04	18.57
10	3x3	5	0.93	7.14	6	1.25	8.57
	5x5	8	1.13	11.42	11	1.10	17.14
20	3x3	5	1.16	7.14	5	1.03	7.14
	5x5	8	1.63	8.57	12	1.34	14.28
40	3x3	7	1.89	10	11	1.82	15.71
	5x5	13	2.19	18.57	12	2.29	17.14
60	3x3	12	2.33	17.14	10	2.60	14.28
	5x5	22	2.79	31.42	17	1.84	24.28
80	3x3	17	2.45	24.28	13	2.49	18.57
	5x5	21	3.42	30	15	2.89	21.42
100	3x3	10	3.67	14.28	16	3.20	14.28
	5x5	27	2.35	22.85	23	2.35	28.57
200	3x3	9	7.88	20	11	5.36	15.71
	5x5	17	6.72	24.28	9	5.55	12.85

Tableau III.4 : la classification avec une résolution 0.1 (image de 25x32 pixels)

A partir des résultats obtenus sur la base Yalfaces, nous constatons, que plus on augmente le nombre de carte, plus le taux d'erreur de classification diminue. Cependant à partir d'un certain nombre, le taux d'erreur commence à croître. Ce qui est pareil pour la résolution, plus elle diminue plus le taux augmente, en comparant les trois tableaux. Cela semble évident, nous perdons plus de détails dans l'image avec la diminution de la résolution de celle-ci. D'après ces premiers résultats, nous avons choisi la résolution de 0.2 pour la suite des tests.

III.3.2.2 Résultats de la classification de la base ALOI

Les résultats de classification de la base ALOI sont donnés dans les tableaux ci-dessous en fonction des 4 partitions.

1^{ère} partition : pour l'apprentissage, nous avons utilisé 4 images par objet avec un pas de rotation de 90° en commençant de la position initiale de l'objet (0°), pour classer 4 images avec le même pas de rotation, cette fois en commençant par la position de (45°) de l'objet. D'après le tableau III.5, nous remarquons que le nombre d'images mal classées est de 3 sur 40 images au total, ce qui correspond à un taux d'erreur de 7.5% et donc un taux de bonne classification de 92.5 %. Ce résultat est obtenu avec 20 cartes et une taille de 3x3 pour les deux masques convolution et *pooling*.

Nbre de carte	Taille de pooling	Nbre images mal classées avec masque conv 3x3	Temps test(s)	Taux erreur (%)	Nbre images mal classées avec masque conv 5x5	Temps test(s)	Taux erreur(%)
5	3x3	4	0.71	10	6	0.69	15
	5x5	6	0.61	15	8	0.70	20
10	3x3	6	0.71	15	6	0.89	15
	5x5	6	0.73	15	9	1.06	22.5
20	3x3	3	1.29	7.5	5	1.16	12.5
	5x5	6	1.18	15	6	1.19	15
40	3x3	5	1.81	12.5	7	1.81	17.5
	5x5	6	2.16	15	6	2.04	20
60	3x3	5	3.5	12.5	5	2.98	12.5
	5x5	6	3.42	15	6	3.11	15
80	3x3	4	4.70	10	5	4.39	12.5
	5x5	5	4.97	12.5	8	4.51	20
100	3x3	5	6.56	12.5	5	6.19	12.5
	5x5	7	7.28	17.5	7	6.44	17.5

Tableau III.5 : Résultats classification en utilisant la 1^{ère} partition

2^{ème} partition : pour l'apprentissage, nous avons utilisé 8 images par objet avec un pas de rotation de 45° en commençant de la position initiale de l'objet (0°), pour classer 12 images avec un pas de rotation de 25°, cette fois en commençant par la position de (25°) de l'objet. D'après le tableau III.6, nous constatons, que pour cette répartition, le taux de bonne classification atteint les 100% pour 5 et 10 cartes et taille 5x5 pour le masque de convolution et différentes taille pour celui du *pooling*.

Nbre de carte	Taille de pooling	Nbre images mal classées avec masque conv 3x3	Temps test(s)	Taux erreur (%)	Nbre images mal classées avec masque conv 5x5	Temps test(s)	Taux erreur (%)
5	3x3	0	2.39	0	2	2.25	1.42
	5x5	4	2.19	2.85	0	2.57	0
10	3x3	1	3.15	0.71	0	3.33	0
	5x5	1	3.42	0.71	0	3.17	0
20	3x3	1	5.87	1.42	2	5.10	1.42
	5x5	2	5.94	1.42	3	5.36	2.14
40	3x3	1	11.58	0.71	3	10.31	2.14
	5x5	2	12.21	1.42	4	11.17	2.85
60	3x3	3	19.81	2.14	2	17.91	1.42
	5x5	3	19.08	2.14	4	18.70	2.85

Tableau III.6 : Résultats classification en utilisant la 2^{ème} partition

3^{ème} partition : D'après le tableau III.7, nous remarquons, que même pour cette partition, Le taux de bonne classification atteint aussi les 100% avec un nombre de cartes 5, 20 et 80

Nbre de carte	Taille de pooling	Nbre images mal classées avec masque conv 3x3	Temps test(s)	Taux erreur (%)	Nbre images mal classées avec masque conv 5x5	Temps test(s)	Taux erreur (%)
5	3x3	0	2.21	0	2	1.14	2.50
	5x5	3	1.29	3.75	1	1.24	1.25
10	3x3	1	1.50	1.25	2	1.48	2.50
	5x5	1	1.53	1.25	1	1.49	1.25
20	3x3	1	2.18	1.25	2	2.12	2.50
	5x5	3	2.60	3.75	0	4.21	0
40	3x3	2	4.73	2.50	3	4.54	3.75
	5x5	4	5.10	5	2	5.10	2.50
60	3x3	1	7.99	1.25	3	8.50	3.75
	5x5	4	9.10	5	3	8.10	3.75
80	3x3	2	17.43	2.50	0	10.18	0
	5x5	5	22.01	6.25	2	11.52	2.50

Tableau III.7 : Résultats classification en utilisant la 3^{ème} partition

4^{ème} partition : cette partition est utilisée pour la classification des 10 objets les plus similaires contenant dans la base ALOI. D'après le tableau III.8, nous constatons que le nombre minimal d'images mal classées est de 40 images sur 180 images au total, ce qui correspond au taux de bonne classification de 77.88%, le temps de test varie entre [2.63s 9.61s], et le taux d'erreur varie entre [22.22% 38.55%].

Nbre de carte	Taille de pooling	Nbre images mal classées avec masque conv 3x3	Temps test(s)	Taux erreur (%)	Nbre images mal classées avec masque conv 5x5	Temps test(s)	Taux erreur (%)
5	3x3	52	4.40	28.88	53	2.63	29.44
	5x5	40	2.94	22.22	41	3.01	22.77
10	3x3	59	4.48	32.77	63	4.33	35.00
	5x5	44	2.81	24.44	60	4.29	33.33
20	3x3	60	9.61	33.33	59	7.69	32.77
	5x5	68	8.53	38.55	57	8.00	31.66

Tableau III.8 : Résultats classification en utilisant la 4^{ème} partition

III.3.3 interprétation des résultats des deux bases ALOI

III.3.3.1 Influence des taux d'exemples d'apprentissage

Les résultats de la 1^{ère} partition ne sont pas assez satisfaisants, ceci s'explique par le manque d'images d'apprentissage et ainsi le pas rotation de 90° de sélection des images d'apprentissage qui entraîne une grande variabilité dans les exemples d'apprentissage ainsi ceux de test.

Concernant les résultats de la 2^{ème} et la 3^{ème} partition sont satisfaisants, les erreurs sont rares et le taux de bonne classification atteint les 100%, donc l'ELM-LRF à une bonne capacité de généralisation.

En final, les résultats de la 4^{ème} partition sont acceptables, même si le taux d'erreur est de 18,88% et que le taux de classification n'est aussi élevé. 34 images sur 180 images qui ne sont pas bien classées, en raison de la très grande ressemblance entre les 10 objets deux à deux, même pour l'être humain, il lui est difficile de les différencier (voir figure III.4). Sur la figure III.10, nous montrons un exemple de confusion des objets.



Objet 5 avec angle de rotation 290°



objet 50 avec angle de rotation 290°

Figure III.10 : confusion entre les objets de deux classes étiquetées différemment

III.3.3.2 Influence du nombre de cartes

Pour les deux bases yalefaces et ALOI, l'utilisation des images avec leur taille initiale génère un problème de manque d'espace mémoire parce que le vecteur de caractéristiques est très grande taille, qui est égale aux nombre de pixels constituant l'image multiplié par le nombre de carte (voir tableau III.9. Pour cela nous avons réduit la taille de l'image en utilisant différentes types de résolution (0.5, 0.2 ,0.1). Sur le tableau III.9, nous donnons un exemple de la taille de vecteur de caractéristiques, pour chaque base avec 5 cartes, et différentes résolutions. Pour la base ALOI, nous n'avons utilisé que la résolution 0.2.

Résolution	La taille du vecteur caractéristique	
	Base Yalefaces	Base ALOI
Sans modification	388800	414720
0.5	75640	---
0.2	11270	16965
0.1	775	---

Tableau III.9 : La taille de vecteur de caractéristiques

Le nombre de cartes varie inversement par rapport à la taille des images, c-à-d pour une image de taille très grande, peu de cartes (par exemple 5) suffisent pour avoir un bon taux de classification et le contraire est juste d'après les résultats que nous avons obtenus. Mais plus la résolution est petite (réduction de la taille de l'image) plus le taux de bonne classification diminue. Cela est dû au fait de perte de beaucoup de détails. En plus, le nombre de cartes ainsi la taille de l'image influent de manière linéaire sur le temps de l'exécution.

III.3.3.3 Influence de la taille du masque de convolution

La taille de masque influe sur la classification des images, elle dépend de la qualité des détails présents dans l'image. Si les détails sont très fins, alors vaut mieux prendre un petit masque et le contraire est juste. D'après les résultats obtenus, la taille du masque la plus appropriée pour les deux bases est de 3x3.

III.3.3.4 Influence de la taille de masque de pooling

La taille du masque de *pooling* à peu d'influence sur les résultats de la classification, sauf que ne l'avons pas varié de manière suffisante pour tirer une conclusion sur son influence. En plus nous avons fait quelques tests sans la structure de *pooling*, nous avons constaté que les résultats ne changent pas beaucoup. Nous avons obtenus presque les même taux de bonne classification.

III.4 Conclusion

D'après toutes ces expérimentations nous pouvons tirer plusieurs conclusions à savoir :

- Le réseau ELM-LRF est d'une architecture très simple et facile à mettre en œuvre comparativement par rapport aux réseaux de neurones à convolution.
- La notions de champs récepteurs permet d'extraire un vecteur de caractéristiques le plus représentatif de l'image.
- Le temps de l'exécution (apprentissage et test) est relativement très court par rapport aux réseaux de neurones à convolution.
- Le réseau ELM-LRF a montré une bonne capacité d'apprentissage et de généralisation sur deux types d'images : niveaux de gris et couleurs.
- Les paramètres du réseau, le nombre de cartes la taille des masques de convolution et de *pooling*, sont très simple à ajuster, il suffit d'avoir certaines connaissances concernant les images à classer.

Conclusion générale

Après avoir étudié, dans le premier chapitre, les réseaux de neurones et leurs utilités dans différents domaines, dans le deuxième chapitre nous nous sommes intéressés à l'algorithme d'apprentissage ELM-LRF qui est un type de réseaux de neurones *feedforward* et que nous avons utilisé dans notre travail, pour la classification des images couleur et au niveau de gris.

Le réseau que nous avons étudié permet à l'utilisateur de classer les images brutes sans aucun prétraitement et sans l'étape d'extraction de caractéristiques. Ce réseau ELM-LRF est basé sur la notion des champs récepteurs locaux, inspirée des réseaux de neurones à convolution afin d'apprendre les corrélations locales des images d'entrée. Les neurones de la couche d'entrée et ceux de la couche cachée sont connectés localement, ce qui permet au réseau de considérer toute la structure de l'image.

Les résultats obtenus, sur les deux bases d'images yalefaces et ALOI, sont assez satisfaisants montrant que ce réseau a une bonne capacité de généralisation, dans certains cas le taux de bonne classification atteint les 100%. Ce réseau peut être considéré comme un approximateur universel, vu que presque la totalité des paramètres sont indépendants des images à classer. Seul les poids de sortie sont calculés de manière analytique, par conséquent, l'apprentissage est rapide et ne nécessite aucune itération. Le réseau ELM-LRF n'a qu'une seule couche de convolution et une couche de *pooling*. D'après les différents tests effectués, nous constatons qu'avec peu de cartes, qui est équivalent au nombre de neurones cachés, les résultats de classification sont assez satisfaisants.

En guise de perspectives, il serait intéressant d'utiliser les images avec leur taille réelle à l'entrée du réseau. En plus d'utiliser un très grand intervalle de variations du nombre de cartes ainsi que pour la taille des deux masques, afin de tirer de bonnes conclusions concernant ce réseau. Ce que nous n'avons pas pu faire en raison de la faible capacité de notre machine.

Perspectives

Il serait important d'étudier le phénomène aléatoire pour régler les problèmes de l'instabilité de réseau (comment régler les paramètres).

Dans notre travail nous avons utilisé deux types d'images (en niveau de gris) et (couleur), et on a obtenus de résultats satisfaisant, il serait intéressant d'utilisé ce réseau pour la classification des images texturé.

- [1] **WIRA, Patrice.** *Réseaux de neurones artificiels: architectures et applications.* Université de Haute Alsace, laboratoire MIPS, p. 49-56. avril, 2009.
- [2] **Jérôme DAMELIN COURT.** *Présentation & historique des réseaux neuronaux.* 1/1.2017.%
- [3] **ZERDOUMI, Zahra.** *Application des réseaux de neurones artificiels à la poursuite des non linéarités fluctuantes des systèmes satellitaires.* Thèse de doctorat. Université Mohamed Boudiaf de M'sila.2006.
- [4] **P. Rougier Nicolas .** *perceptron simple, perceptron multicouche .* université de bordeaux cours Master 2 - Sciences Cognitives.
- [5] **OUSSAR, Yacine.** *Réseaux d'ondelettes et réseaux de neurones pour la modélisation statique et dynamique de processus.* Thèse de doctorat. Université Pierre et Marie Curie-Paris VI, 1998.
- [6] **IDIOU GHania.** *Régression et modélisation par les réseaux de neurones,* mémoire de magistère, université Mentouri .Constantine, 30 juin 2009.
- [7] **Sylvain Barthélémy .** *introduction aux réseaux de neurones .* juin 2000.
- [8] **TIRILLY Pierre.** *évaluation des performances des réseaux de neurones aléatoire et application a la Bio-informatique.* Rapport de stage ,8 février 2006.
- [9] **:NOURESSADAT, MERZOUKA.** *Etude des performances des réseaux de neurones dynamiques à représenter des systèmes réels: une approche dans l'espace d'état.* Mémoire de magister en Contrôle, Université de Setif, vol. 1,2009
- [10] **G.DREYFUS .***réseaux de neurones .Ecole supérieur de physique et de chimie industrielle.* laboratoire électronique, 1998
- [11] **Gérard DREYFUS, A.Kodsi, T.Luong, R.Lauranson, G.Giraud, A.SADEGHi.** *Reconnaissance de formes par réseaux de neurones.* Rapport. Ecole polytechnique, juillet 2002.
- [12] **LAOUAMER LAMRI.** *Approche exploratoire sur la classification appliquée aux images.* Thèse de doctorat. Université du Québec à Trois-Rivières,2006
- [13] **ANDREI DONCESCU** « les réseaux de neurones artificiels ».
- [14] **Cloud Touzet .** *les réseaux de neurones artificiels, introduction au connexionnisme.* livre Edition I, 1992
- [15] **BELHADJ NORA et BELMAHDI FATIHA .***application des réseaux de neurones a la détection et la classification des défauts dans les machines tournantes .*mémoire de fin d'études d'ingénieur en électronique, UMMTO, 2009.

- [16] **AMMAR Mohamed Yessin.** *Mise en œuvre de réseaux de neurones pour la modélisation de cinétiques réactionnelles en vue de la transposition batch/continu.* Thèse de doctorat, institut national polytechnique de Toulouse, 2007.
- [17] **GANA Massine .***implémentation d'un réseau de neurones dans un microcontrôleur.* Mémoire fin d'étude en électronique UMMTO, 2016.
- [18] **Philippe JAUFFRET.** *Introduction aux réseaux de neurones.* laboratoire des systèmes d'informatique chimique, UMR 5076 du CNRS – Montpellier, 2002
- [19] **BIAN, Xi-Hui, LI, Shu-Juan, FAN, Meng-Ran, et al.** *Spectral quantitative analysis of complex samples based on the extreme learning machine.* Analytical Methods, vol. 8, no 23, p. 4674-4679, 2016
- [20] **HUANG, Guang-Bin.** *What are extreme learning machines? Filling the gap between Frank Rosenblatt's dream and John von Neumann's puzzle.* Cognitive Computation, vol. 7, no 3, p. 263-278, 2015.
- [21] **Yann Lecun.** *Convolutionnel networks .* 2017
- [22]**HUANG, Guang-Bin, ZHU, Qin-Yu, et SIEW, Chee-Kheong.** *Extreme learning machine: theory and applications.* Neurocomputing, vol. 70, no 1, p. 489-501,2006.
- [23]**DING, Shifei, ZHAO, Han, ZHANG, Yanan, et al.** *Extreme learning machine: algorithm, theory and applications.* Artificial Intelligence Review, vol. 44, no 1, p. 103-115, 2013...
- [24] **HUANG, Guang-Bin, ZHOU, Hongming, DING, Xiaojian, et al.** *Extreme learning machine for regression and multiclass classification.* IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), vol. 42, no 2, p. 513-529,2012.
- [25] **Guang-Bin Huang.** *Introduction to Extreme learning machine.* School of Electrical and Electronic Engineering Machines, University Singapore, cours Nov 2006.
- [26] **BIAN, Xihui, ZHANG, Caixia, TAN, Xiaoyao, et al.** *A boosting extreme learning machine for near-infrared spectral quantitative analysis of diesel fuel and edible blend oil samples.* Analytical Methods, vol. 9, no 20, p. 2983-2989,2017.
- [27] **HUANG, Guang-Bin.** *Extreme learning machine (Evolutionary learning & optimization),* vol.1,Edition1,2009.
- [28] **HUANG, Guang-Bin, BAI, Zuo, KASUN, Liyanaarachchi Lekamalage Chamara, et al.** *Local receptive fields based extreme learning machine.* IEEE Computational Intelligence Magazine, vol. 10, no 2, p. 18-29,2015.
- [29] **BIAN, Xi-Hui, LI, Shu-Juan, FAN, Meng-Ran, et al.** *Spectral quantitative analysis of complex samples based on the extreme learning machine.* Analytical Methods, vol. 8, no 23, p. 4674-4679, 2016.

[30] **LECUN, Yann, BENGIO, Yoshua, et HINTON, Geoffrey.** *Deep learning.* *Nature*, vol. 521, no 7553, p. 436-444. 2015.

[31] **ROTELLA, Frédéric et BORNE, Pierre.** *Théorie et pratique du calcul matriciel.* Editions technip, 1995.

[32] [http://vision.ucsd.edu/datasets/yale face dataset original /yalfaces.zip](http://vision.ucsd.edu/datasets/yale%20face%20dataset%20original/yalfaces.zip).

[33] <http://aloi.science.uva.nl>.

Les mots clefs :

réseaux de neurones, apprentissage supervisé, apprentissage non supervisé, fonctions d'activation, le réseau feedforward, Apprentissage machine extrême(*Extreme Learning machine*), champs récepteurs locaux (*Local Receptif Field*), Classification de données, réseaux de neurones à convolution(*Convolutional Neural Network*), extraction de caractéristiques, sous-échantillonnage (*pooling*), algorithmes classiques, Base de données, Base d'images, masque de convolution, masque de pooling, carte de caractéristique.

Résumé :

Dans ce mémoire, on s'est intéressé à présenter les notions de base pour la compréhension des réseaux de neurones, des généralités sur le réseau ELM ainsi son extension ELM-LRF pour la classification des images. L'objectif de ce travail consiste à évaluer ce réseau, et pour cela, nous l'avons testé sur deux bases différentes. La base des images Yalefaces, en niveau de gris, pour la reconnaissance de personnes et la base des images ALOI, en couleur, de 1000 objets. L'algorithme ELM a été implémenté sous Matlab et il a montré une bonne capacité d'apprentissage et de généralisation sur deux types d'images : niveaux de gris et couleurs, compte tenu des paramètres du réseau, le nombre de cartes la taille des masques de convolution et de *pooling* qui sont très simple à ajuster, donnés en connaissant certaines informations concernant les images à classer.